

UNIVERSIDAD DE BUENOS AIRES  
FACULTAD DE CIENCIAS EXACTAS Y NATURALES

# **Transformers guiados por atención humana: integración de eye-tracking para mejorar el entrenamiento de modelos de lenguaje**

Tesis de Licenciatura en Ciencia de Datos

Tomás Schmidt

Director: Bruno Bianchi

Codirector: Fermín Travi

Buenos Aires, 2026

## Resumen

Este documento presenta un índice tentativo y desarrollado para la tesis. La tesis estudiará la incorporación de señales de eye-tracking en modelos de lenguaje para español, con foco en una fase implementada de supervisión auxiliar con scanpaths medidos y una segunda fase propuesta basada en máscaras de atención guiadas por métricas de lectura.

**Palabras clave:** modelos de lenguaje, Transformers, BETO, eye-tracking, scanpaths, atención humana, modelado de lenguaje enmascarado.

## Agradecimientos

Espacio reservado para los agradecimientos personales e institucionales de la tesis.

## Dedicatoria

Espacio reservado para la dedicatoria.

## 1) Introducción

**Comentario:** Este capítulo de introducción será similar a la presentación para la beca.

Se presentará el contexto general de la tesis: el uso de modelos de lenguaje basados en Transformers y sus limitaciones en escenarios con pocos datos o recursos específicos para español. Se introducirá la idea de utilizar señales de lectura humana como fuente adicional de información durante el entrenamiento.

### Problema abordado y objetivo

Se describirá el problema central: existen pocos enfoques que integren datos de eye-tracking en modelos de lenguaje para español. Se formularán el objetivo general y los objetivos específicos de la tesis.

### Contribuciones

Se resumirán los principales aportes esperados: adaptación de una arquitectura de supervisión con scanpaths al español, construcción de un pipeline de alineación palabra-subtoken, incorporación de una rama auxiliar de lectura y propuesta de una segunda fase basada en atención guiada por métricas de lectura.

### Organización de la tesis

Se describirá brevemente la estructura de los capítulos, indicando qué rol cumple cada uno dentro del desarrollo general de la tesis.

## 2) Marco teórico

### 2. 1 Modelos de lenguaje basados en Transformers-

#### -Procesamiento del lenguaje natural

Se introducirá brevemente el área de procesamiento del lenguaje natural y algunas de sus tareas principales, como clasificación de texto, análisis de sentimiento, inferencia textual y modelado de lenguaje. El objetivo será dar el contexto mínimo necesario para entender el uso de modelos de lenguaje en esta tesis.

- Representación de texto

Se explicará cómo el texto se transforma en una representación numérica para poder ser procesado por una red neuronal. Se introducirán conceptos como tokenización, vocabulario, subtokens y *embedding*, entendido como una representación vectorial aprendida de una unidad textual.

- Modelos de lenguaje, preentrenamiento y ajuste fino

Se presentará qué es un modelo de lenguaje y cuál es su rol en el aprendizaje de representaciones textuales. Se diferenciará entre preentrenamiento y ajuste fino, destacando que esta tesis utiliza una etapa de adaptación previa a la evaluación en tareas posteriores.

- Modelado de lenguaje enmascarado

Se explicará la tarea de modelado de lenguaje enmascarado utilizada por modelos tipo BERT. Se describirá la idea de ocultar algunos tokens de la entrada y entrenar al modelo para reconstruirlos a partir del contexto.

- Arquitectura Transformer

Se presentará la arquitectura Transformer como base de los modelos utilizados en la tesis. Se explicará de forma general el rol de la atención, la autoatención, las capas del codificador y la construcción de representaciones contextualizadas.

- BERT y BETO

Se describirá BERT como un modelo basado en el codificador del Transformer y se presentará BETO como una adaptación para español. Se justificará el uso de BETO como modelo base para trabajar con textos en español.

## 2.2 Eye-tracking y lectura

### - Movimientos oculares durante la lectura

Se introducirá el eye-tracking como técnica para registrar la mirada durante la lectura. Se explicará que estas señales permiten estudiar aspectos del procesamiento humano del lenguaje.

### - Atributos de lectura

Se presentarán los principales atributos utilizados para describir el comportamiento ocular durante la lectura. En particular, se definirán fijaciones, sacadas y regresiones, y se explicará qué información puede aportar cada una sobre el proceso de lectura.

### - Medidas de lectura

Se presentarán métricas agregadas de eye-tracking, como duración de la primera fijación, tiempo total de lectura, número de fijaciones, omisiones y regresiones. Se distinguirá entre métricas tempranas y tardías, ya que esta diferencia será relevante para la propuesta metodológica.

### - Scanpaths

Se definirá el concepto de *scanpath* como la secuencia temporal de fijaciones durante la lectura. Se explicará por qué esta representación es especialmente importante en esta tesis, dado que permite modelar el orden real en que una persona recorre un texto.

### - Limitaciones del uso de eye-tracking

Se mencionarán limitaciones prácticas, como el costo de recolección, el ruido en las mediciones, la variabilidad entre lectores, el tamaño reducido de los datasets y la dificultad de contar con estas señales durante la inferencia.

## 3 Metodología propuesta

### 3.1 Descripción general de las fases

Se presentará la metodología como un enfoque organizado en dos fases. La Fase A corresponderá a la arquitectura implementada con supervisión auxiliar por scanpaths medidos; la Fase B corresponderá a una propuesta de integración directa en el mecanismo de atención mediante métricas de lectura. Se explicará la motivación común de ambas fases: aprovechar señales de lectura humana para guiar el entrenamiento de modelos de lenguaje, manteniendo la posibilidad de usar el modelo final solo con texto.

Se explicará cómo ambas fases se complementan: la Fase A permitirá una integración modular y ya implementada, mientras que la Fase B explorará una intervención más directa dentro del Transformer.

### 3.2 Fase A: supervisión auxiliar con scanpaths medidos

**Comentario:** En la sección 2 ya se dio una descripción detallada de las arquitecturas. Con lo cual, para 6.2.3, 6.2.5 y 6.2.8 no se describirán en detalle las funciones/arquitecturas, sino que se focalizará en cómo se combinan con eye attention.

#### Paper base

Se presentará el trabajo original en el que se basa esta fase. Se describirá su objetivo general: incorporar una rama de scanpath durante el entrenamiento para guiar al modelo con señales similares a la lectura humana.

#### Idea general del método original

Se explicará el método original de forma resumida: un Transformer produce representaciones contextualizadas, estas se reordenan según un scanpath y luego se procesan con una GRU para calcular una pérdida auxiliar.

#### Adaptación propuesta

Se describirán las modificaciones realizadas en esta tesis. En particular, se adaptará el enfoque al español, se utilizará BETO como modelo base, se reemplazarán scanpaths sintéticos por scanpaths medidos y se aplicará el método en una etapa de modelado de lenguaje enmascarado.

#### Datos de entrada

Se detallarán los elementos que recibe la Fase A: texto tokenizado, identificadores de palabra, scanpaths medidos y longitudes de scanpath. También se explicará cómo estos



elementos conectan la rama textual con la rama auxiliar. La descripción de qué es cada dato se deberá realizar en la sección 5. En esta sección se buscará mostrar cómo se utilizan.

### **Modelado de lenguaje enmascarado**

Se describirá la tarea principal de entrenamiento. El modelo recibirá oraciones con algunos tokens enmascarados y deberá predecir los tokens originales usando el contexto disponible.

### **Enmascaramiento dinámico**

Se explicará que los tokens enmascarados se seleccionan dinámicamente durante el entrenamiento, en lugar de fijar siempre las mismas posiciones. Esta decisión buscará reducir sobreajuste, especialmente cuando existen múltiples lecturas de textos similares.

### **Rama auxiliar de scanpath**

Se describirá la rama auxiliar que toma las representaciones contextualizadas de BETO, las reordena según el scanpath medido y las procesa como una secuencia temporal de lectura humana.

### **Codificador GRU**

Se explicará el rol de la GRU como codificador secuencial de la trayectoria de lectura. La GRU resumirá la secuencia reordenada de representaciones y producirá una salida utilizada por la pérdida auxiliar.

### **Función de pérdida**

Se presentará la combinación entre la pérdida principal de modelado de lenguaje enmascarado y la pérdida auxiliar asociada al scanpath. Se introducirá el peso que controla la influencia relativa de la señal de eye-tracking.

### **Entrenamiento e inferencia**

Se describirá el flujo durante entrenamiento y se aclarará que la rama de scanpath se utiliza solo en esa etapa. En inferencia, el modelo conservará únicamente la rama textual, por lo que no requerirá datos de eye-tracking.

### **3.2.2 Resultados de Fase A**

### **Preguntas experimentales**

Se formularán las preguntas que guían la experimentación.

## Configuración general

Se describirán los aspectos comunes a los experimentos: modelo base, tokenizador, longitud máxima, tamaño de lote, tasa de aprendizaje, número de épocas, semillas, +METRICAS, hardware y librerías utilizadas.

**Comentario:** Métricas va a ser presentado dentro de configuración general, pero lo dejo como sección aparte.

## “Preentrenamiento” + Tareas posteriores

Se detallará la etapa de entrenamiento sobre el corpus de lectura. Se compararán variantes con modelado de lenguaje enmascarado únicamente y con modelado de lenguaje enmascarado más supervisión por scanpaths.

Se presentarán las tareas de evaluación posteriores en español. Se describirá brevemente cada dataset, el tipo de entrada, el número de clases y el objetivo de la tarea.

## Resultados principales

Se reservará esta sección para presentar las tablas centrales de resultados. No se inventan valores; aquí se compararán los modelos según las métricas definidas.

## Análisis cualitativo

Se propondrá incluir ejemplos de oraciones, scanpaths y posibles patrones de fijación. El objetivo será brindar intuición sobre qué información aportan las señales de lectura.

### 3.2.3 Discusión Fase A

## 3.3 Fase B: máscaras de atención guiadas por métricas de lectura

### Paper base

Se presentará el trabajo base de esta fase, centrado en modificar la atención de modelos Transformer mediante máscaras construidas a partir de métricas de eye-tracking.

### Idea general del método original

Se explicará la idea principal del enfoque: transformar métricas de lectura, como duración de primera fijación o tiempo total de lectura, en sesgos que se agregan a los puntajes de atención antes del *softmax*.

### Adaptación propuesta

Se describirá cómo se adaptaría este enfoque al caso de la tesis: uso de métricas medidas en español, integración con BETO y posible aplicación durante una etapa de preentrenamiento o adaptación al dominio.

### Construcción de máscaras de atención

Se describirá cómo se transformarían las métricas por palabra en matrices o sesgos de atención. Se incluirá la normalización de las métricas, la expansión a subtokens y la combinación de varias señales.

### Integración en el Transformer

Se explicará dónde se insertaría la señal cognitiva dentro del cálculo de atención. La máscara de lectura se agregaría a los puntajes de atención antes de la normalización, diferenciándose de la máscara estándar de padding.

### Distribución por capas o cabezas

**Comentario:** Todavía no está implementado, aunque me gustaría.

Se propondrá una adaptación propia: usar métricas tempranas en capas o cabezas iniciales y métricas tardías en capas o cabezas finales. Esta idea se apoyará en la interpretación de que las primeras capas capturan información más local y las últimas información más contextual.

#### 3.3.2 Resultados Fase B

#### 3.3.3 Discusión Fase B

### 3.3.3 Discusión

#### Interpretación de resultados

Se discutirán los resultados obtenidos en relación con las preguntas experimentales. Se diferenciarán conclusiones sólidas de tendencias preliminares.

#### Impacto y limitaciones de los scanpaths

Se analizará específicamente si los scanpaths medidos aportan mejoras o cambios relevantes frente a los modelos sin supervisión de eye-tracking. Se presentarán las principales limitaciones del trabajo: tamaño del corpus, dominio de los textos, ruido en la medición, alineación palabra-subtoken, costo de entrenamiento y variabilidad entre lectores.

#### Comparación con trabajos previos

Se volverá sobre el trabajo relacionado para ubicar los resultados de la tesis. Se destacará qué aspectos coinciden con estudios anteriores y cuáles constituyen una adaptación propia.

### 3.4 Comparación entre Fase A y Fase B

Se comparará la señal usada en cada fase: scanpaths completos en la Fase A, aplicados a una rama auxiliar externa al Transformer, y métricas de lectura que se agregan al mecanismo de atención del Transformer en la Fase B.

#### Ventajas y limitaciones

Se resumirán las ventajas de cada enfoque. La Fase A será modular y más fácil de apagar en inferencia; la Fase B permitirá una integración más directa con la atención del modelo.

Se mencionarán limitaciones de ambas fases, incluyendo complejidad de implementación, sensibilidad a la alineación, dependencia de métricas confiables y posible inestabilidad durante el entrenamiento.

**Comentario:** Acá tengo una duda muy grande.

No tengo bien claro cómo quiero armar el orden entre los capítulos 6 y 7.

Por ahora tengo pensado que, para el capítulo 6, voy a dar una descripción más conceptual de las modificaciones de la arquitectura elegida, pero sin meterme en detalle en su implementación. Esta idea de un “preentrenamiento” con CUENTOS es central y una de las mayores diferencias con los papers originales que usaban scanpaths sintéticos. Pero siento que, si lo nombro en el capítulo 6, queda medio desconectado del resto de la implementación. Es decir, si nombro el

“preentrenamiento” con CUENTOS, resulta obligatorio contar las tareas extrínsecas, porque es donde se apaga la máscara/rama auxiliar.

Por lo tanto, mi primer enfoque va a ser describir de una manera más conceptual las ideas en el capítulo 6 e ir a la parte más implementativa en el capítulo 7.

## **Discusión**

### **Interpretación de resultados**

Se discutirán los resultados obtenidos en relación con las preguntas experimentales. Se diferenciarán conclusiones sólidas de tendencias preliminares.

### **Impacto y limitaciones de los scanpaths**

Se analizará específicamente si los scanpaths medidos aportan mejoras o cambios relevantes frente a los modelos sin supervisión de eye-tracking. Se presentarán las principales limitaciones del trabajo: tamaño del corpus, dominio de los textos, ruido en la medición, alineación palabra-subtoken, costo de entrenamiento y variabilidad entre lectores.

### **Comparación con trabajos previos**

Se volverá sobre el trabajo relacionado para ubicar los resultados de la tesis. Se destacará qué aspectos coinciden con estudios anteriores y cuáles constituyen una adaptación propia.



## Datos y preprocesamiento

### Dataset de lectura en español

Se describirá el corpus de lectura utilizado en la tesis, compuesto por textos en español y registros de eye-tracking. Se presentarán de forma general los cuentos, participantes, lecturas y señales disponibles.

### Estructura de los datos

Se detallará cómo están organizados los datos originales. Se describirán los campos principales, como texto, identificadores de palabras, scanpaths, medidas de lectura y unidades de análisis.

### Generación y limpieza del texto

Se explicarán las decisiones para generar los inputs a partir de cada scanpath medido. Es decir, a partir de los scanpaths y el texto original de CUENTOS, se extrae un input de CUENTOS que corresponda con el scanpath. Luego, se limpian los inputs por tamaño.

### Segmentación en palabras

Se describirá cómo se obtiene la secuencia de palabras de cada oración o fragmento. Esta segmentación será necesaria porque las fijaciones y scanpaths se encuentran originalmente definidos a nivel palabra.

### Tokenización con BETO

Se explicará cómo se tokeniza el texto usando el tokenizador de BETO. Se destacará que una palabra puede dividirse en varios subtokens, lo cual introduce un problema de alineación con las señales de eye-tracking.

### Alineación palabra-subtoken

**Comentario:** El punto 5.5 y 5.6 los uniría en uno que se llame “Alineación palabra-token”, donde comienzo contando que tokenizo el texto con BETO y cómo resuelvo el problema de alinear los tokens a las palabras: repitiendo las métricas de la palabra original en cada token.

Se describirá el procedimiento para asociar cada subtoken con la palabra original correspondiente. Esta alineación será central para poder transferir información de fijaciones desde el nivel palabra al nivel de entrada del modelo.



## Construcción y alineación de scanpaths

Se explicará cómo se representan los scanpaths medidos como secuencias de índices de palabras. Se considerarán refijaciones, regresiones, marcadores especiales y control de longitudes.

Se describirá cómo se transforma un scanpath definido sobre palabras en una secuencia de posiciones sobre tokens o subtokens. Esta conversión permitirá reordenar las representaciones producidas por BETO según el orden de lectura.

## Construcción de entradas del modelo

**Comentario:** Esta sección no sé si es ir muy a detalle. Yo lo tengo explicado para mí mismo, pero no sé si es relevante para la tesis.

Se describirán los tensores utilizados por el modelo: identificadores de tokens, máscara de atención, etiquetas para modelado de lenguaje enmascarado, identificadores de palabra y scanpaths medidos.

## División en entrenamiento, validación y evaluación

Se explicará el criterio de partición de los datos. Se enfatizará la necesidad de evitar que una misma oración aparezca en entrenamiento y evaluación con distintos lectores, para reducir fuga de información.

## Estadísticas del corpus

**Comentario:** Esto creo que no va. Tal vez en el anexo. Igualmente, hay un par de cosas que son relevantes, como la cantidad de inputs repetidos.

Se presentarán estadísticas descriptivas del corpus procesado, como cantidad de ejemplos, longitud promedio de textos, longitud promedio de scanpaths, número de participantes y distribución de particiones.

## **Conclusiones**

### **Resumen del trabajo**

Se sintetizará el recorrido de la tesis: procesamiento de datos de lectura, alineación con BETO, incorporación de una rama auxiliar y evaluación experimental.

### **Conclusión general y aportes de la tesis**

Se planteará la conclusión conceptual del trabajo: las señales de lectura humana pueden utilizarse como supervisión auxiliar para modelos de lenguaje, aunque su integración requiere decisiones cuidadosas de alineación, arquitectura y evaluación.

### **Trabajo futuro**

Se presentarán líneas futuras, incluyendo ampliar datos, mejorar la alineación, incorporar nuevas métricas, implementar variantes de máscaras de atención y profundizar el análisis de bajo recurso.

## **Apéndices**

### **Hiperparámetros**

Se incluirán tablas con los hiperparámetros usados en cada experimento: tasas de aprendizaje, tamaños de lote, épocas, semillas, pesos de pérdidas y longitudes máximas.

### **Ejemplos de alineación**

Se mostrarán ejemplos detallados de texto original, palabras, subtokens, identificadores de palabra y scanpaths convertidos a posiciones de token.

### **Tablas adicionales**

Se reservará espacio para resultados completos por semilla, tareas adicionales o variantes que no entren en el cuerpo principal de la tesis.

### **Comandos de entrenamiento**

Se documentarán los comandos o scripts utilizados para reproducir las corridas principales.

### **Detalles de implementación**

Se incluirán notas técnicas sobre la organización del código, funciones principales y decisiones de implementación que sean útiles para reproducibilidad.

## Bibliografía

La bibliografía se incorporará con BibTeX o BibLaTeX en la versión final de la tesis. En esta versión preliminar se deja indicada la sección correspondiente.