



UNIVERSIDAD DE BUENOS AIRES
FACULTAD DE CIENCIAS EXACTAS Y NATURALES
DEPARTAMENTO DE COMPUTACIÓN

Procesamiento del lenguaje durante la lectura y los impactos de la fatiga

Tesis de Licenciatura en Ciencias de la Computación

Sebastián Cantini Budden

Director: Dr. Bruno Bianchi

Codirector: Fermín Travi

Buenos Aires, 2025

Procesamiento del lenguaje durante la lectura y los impactos de la fatiga

A pesar de no darnos cuenta, durante la lectura, los ojos se mueven de forma compleja. Este movimiento no es tan simple como un movimiento continuo y secuencial de izquierda a derecha, sino que los ojos se mueven realizando pequeños saltos, con pequeñas pausas en el medio, saltando palabras, y, cada tanto, volviendo a leer palabras ya leídas.

Los patrones resultantes de estos movimientos oculares no son esporádicos, si no que reflejan los procesos cognitivos subyacentes a la lectura. La presente tesis investiga el procesamiento del lenguaje y cómo la fatiga cognitiva impacta sobre él, a través del análisis de los movimientos oculares durante la lectura. Se realizó un análisis exploratorio de los movimientos oculares de 76 participantes hispanohablantes que leyeron hasta 20 historias cortas en español, sobre los cuales se registraron métricas como la duración de la primera fijación, el tiempo de lectura de primera pasada y las palabras saltadas. La metodología de análisis utilizada consiste en modelos lineales mixtos para examinar cómo variables léxicas (longitud y frecuencia de la palabra), de posicionamiento (índice en el texto, oración y pantalla) y la tasa de regresión predicen los patrones de lectura. La fatiga se estimó mediante un puntaje compuesto por dos componentes: las horas de sueño en la noche anterior y el tiempo transcurrido desde el despertar. Adicionalmente, se diseñó un experimento web complementario para estimar la predictibilidad léxica de cada palabra mediante una tarea tipo cloze, donde los participantes debían completar palabras faltantes basándose en el contexto previo.

Los hallazgos de este estudio corroboran el impacto de las variables léxicas y de la posición de las palabras, en consonancia con la literatura previa. Asimismo, al incorporar la fatiga en el análisis, se observaron cambios en la relevancia de algunos predictores y surgieron interacciones significativas: la fatiga modificó la estructura óptima de los modelos, alterando la importancia de la posición de la palabra en el texto para la duración de la primera fijación e impactando de manera diferencial la longitud y frecuencia de la palabra en el tiempo de lectura de primera pasada. Además, se observó un incremento en la tasa de regresión asociado a mayor fatiga, consistente con la reducción de capacidad de retención reportada en la literatura. Estos resultados evidencian un problema habitualmente ignorado en el campo: las métricas oculares dependen parcialmente del nivel de cansancio de los sujetos, lo cual constituye una posible fuente de variación que podría llevar a atribuir erróneamente los resultados a otros factores. Por consiguiente, resulta fundamental incorporar variables circadianas en los estudios cognitivos del lenguaje.

Palabras claves: Fatiga, Cloze, Modelos Lineales Mixtos, Lectura, Movimientos Oculares, Eye-tracking.

Procesamiento del lenguaje durante la lectura y los impactos de la fatiga

Despite going unnoticed, during reading, the eyes move in complex ways. This movement is not as simple as a continuous, sequential left-to-right motion; rather, the eyes move in small jumps, with brief pauses in between, skipping words, and occasionally re-reading words that have already been read.

The patterns resulting from these eye movements are not sporadic but reflect the cognitive processes underlying reading. This thesis investigates language processing and how cognitive fatigue impacts it, through the analysis of eye movements during reading. An exploratory analysis was conducted on the eye movements of 76 Spanish-speaking participants who read up to 20 short stories in Spanish, for whom metrics such as first fixation duration, first-pass reading time, and skipped words were recorded. The analytical methodology consists of linear mixed-effects models to examine how lexical variables (word length and frequency), positional variables (index within the text, sentence, and screen), and regression rate predict reading patterns. Fatigue was estimated using a composite score comprising two components: hours of sleep the previous night and time elapsed since waking. Additionally, a complementary web experiment was designed to estimate the lexical predictability of each word through a cloze task, where participants had to complete missing words based on prior context.

The findings of this study corroborate the impact of lexical variables and word position, in line with previous literature. Furthermore, when incorporating fatigue into the analysis, changes in the relevance of certain predictors emerged along with significant interactions: fatigue modified the optimal model structure, altering the importance of word position in the text for first fixation duration and differentially impacting word length and frequency in first-pass reading time. Additionally, an increase in regression rate was observed with greater fatigue, consistent with the reduction in retention capacity reported in the literature. These results highlight a commonly overlooked issue in the field: eye-tracking metrics partially depend on participants' fatigue levels, which constitutes a potential source of variation that could lead to erroneous attribution of results to other factors. Consequently, it is essential to incorporate circadian variables in cognitive studies of language.

Keywords: Fatigue, Cloze, Linear Mixed-Effects Models, Reading, Eye Movements, Eye-tracking.

Agradecimientos

A mi mamá, que ya no está con nosotros por siempre, guiarme a ser mejor y ayudarme a lidiar con todas las dificultades que surgieron a lo largo de tantos años y por ser una fantástica madre.

A mi papá, que me ayudó a mantenerme responsable y con todo lo que necesité para poder enfocarme en la facultad y terminar mis estudios. También por ser tan comprensivo y considerado.

A mis hermanas que fueron mi soporte emocional durante todos estos años y me bancaron en las buenas y en las malas.

A mi novia Lucía, que me ayudó a seguir adelante en los momentos más difíciles y me acompañó con una paciencia enorme durante todo este proceso.

A mis directores, Bruno y Fermín, que me enseñaron un montón y me acompañaron y guiaron en esta gran aventura que me permitió apreciar mucho más el procesamiento lingüístico.

A la secta, mi grupo de amigos de la facultad, con los que siempre nos ayudamos y bancamos para avanzar. Por nunca parar y siempre juntar la fuerzas para seguir hacia adelante. Fueron un enorme soporte y no lo podría haber hecho sin ustedes.

El LIAA, por ser un grupo de gente tan acogedor, que siempre le dan la bienvenida a toda persona interesada.

A la Universidad Pública Argentina, y a la Facultad de Ciencias Exactas y Naturales, por todo lo que me enseñó y no parar de ofrecer oportunidades como la que me hizo llegar hasta donde estoy hoy.

A mi mamá, la mejor madre de todas.

Contenidos

1. Introducción	1
1.1 ¿Cómo leemos?	1
1.2 Métricas	3
1.2.1 Mediciones tempranas	5
1.2.2 Mediciones intermedias	5
1.2.3 Mediciones tardías	6
1.3 Factores que determinan la duración de las fijaciones oculares	6
1.4 Fatiga y la lectura	7
2. Objetivos	8
2.1 Objetivos particulares	8
3. Métodos	9
3.1 Datos	9
3.1.1 Sobre los sujetos	9
3.1.2 Sobre los textos	9
3.1.3 Ejecución	9
3.2 Procesamiento de datos de movimientos oculares	10
3.2.1 Preprocesamiento	10
3.2.2 Cálculo de métricas	11
3.3 Métricas calculadas sobre las palabras	12
3.4 Modelos lineales mixtos	13
3.4.1 Modelos a ajustar	14
3.5 Fatiga	15
3.6 Predictibilidad	16
4. Resultados	18
4.1 Modelos sin fatiga	18
4.1.1 <i>First Fixation Duration</i>	18
4.1.2 First Pass Reading Time	19
4.1.3 Palabras salteadas	20
4.2 Modelos con fatiga	20
4.2.1 <i>First Fixation Duration</i>	20
4.2.2 First Pass Reading Time	21
4.3 Experimento web	22
5. Conclusiones	23
5.1 Trabajo a futuro	24
6. Apéndice	27
6.1 Modelos sin fatiga	27
6.1.1 <i>First Fixation Duration</i>	27
6.1.2 <i>First Pass Reading Time</i>	27

6.1.3	<i>Skipped</i>	28
6.2	Modelos con fatiga	28
6.2.1	<i>First Fixation Duration</i>	28
6.2.2	<i>First Pass Reading Time</i>	31

1. Introducción

Durante la lectura, los ojos se mueven de forma más compleja de lo que solemos percibir. Este movimiento no es simplemente continuo y secuencial de izquierda a derecha, sino que los ojos realizan pequeños saltos, con breves pausas en el medio, saltando palabras y, cada tanto, volviendo a leer palabras ya leídas. Al ser un proceso en gran medida automático e inconsciente, no es común notar esta complejidad. En esta tesis, se analizarán los efectos de diferentes propiedades de las palabras sobre distintas métricas calculadas a partir de los movimientos oculares durante la lectura. El objetivo principal es profundizar el conocimiento sobre los procesos cognitivos que ocurren al leer. Adicionalmente, se estudiará el impacto que puede producir la fatiga cognitiva sobre estas medidas, analizando una dimensión circadiana sobre la que no se encuentran estudios previo en la literatura. Considerar esta variable en el diseño y ejecución de experimentos conductuales podría permitir controlar factores que afectan los resultados. Este estudio podría proporcionar conocimientos valiosos para el futuro desarrollo de experimentos y modelos de lectura.

1.1 ¿Cómo leemos?

Durante la lectura, al igual que en cualquier otro proceso visual, no se incorpora información de forma continua, sino que los ojos se desplazan con movimientos rápidos y discontinuos. Estos ‘espasmos’ o ‘sacudidas’ del ojo son lo que desde la neurociencia cognitiva se denominan **sacadas**. Cada sacada dura entre 20 y 100 milisegundos y tiene entre 20 y 60 grados de amplitud. Las pausas entre sacadas, que duran en promedio unos 250ms, son llamadas **fijaciones** (Rayner et al., 2012). Tanto las sacadas como las fijaciones son respuestas fisiológicas automáticas, es decir, no están bajo nuestro control consciente. Se denomina supresión sacádica a la propiedad fundamental del sistema visual por la cual no percibimos esa discontinuidad en el movimiento de los ojos (Irwin, 1998). Por la supresión sacádica, nuestro sistema visual no incorpora información visual durante el periodo de una sacada. De esta forma, toda la información visual recibida y procesada por nuestro cerebro proviene de las fijaciones, donde el ojo está virtualmente quieto.

Además de la complejidad ya mencionada, una única fijación puede captar una palabra parcial, completa, o incluso más de una. Es decir, cada palabra puede ser leída en una fijación, en múltiples, o saltada directamente. La necesidad de fijar la mirada en palabras individuales, o realizar microajustes, se debe a varias razones, una de las cuales es que la retina (la membrana fotosensible del ojo) no percibe con la misma claridad todo el campo visual. Esto se debe a que las células fotorreceptoras (conos y bastones) no se distribuyen de forma homogénea a lo largo de la retina (Balota and Rayner, 1991). El centro de la retina concentra una gran cantidad de células pequeñas (conos). Esta región se denomina **fóvea**, y permite una visión nítida y a color. A medida que se aleja de la fóvea (zonas denominadas **parafóvea** y **periferia**), la densidad de conos disminuye y aumenta la densidad de bastones (que son más grandes que los conos), lo que reduce la agudeza visual (Figura 1.1). Por todo esto, cuando una palabra no está en el centro de la fijación, su percepción se vuelve más borrosa y menos precisa. Por esta razón, para leer un texto es necesario mover la fóvea sobre cada segmento relevante del mismo.

El estudio de los movimientos oculares permite conocer los procesos cognitivos suby-




Fig. 1.1: Ilustración de una línea de texto que incide sobre las regiones foveal, parafoveal y periférica de la retina. El ejemplo (a) muestra estas regiones en una línea de letras, mientras que (b) demuestra la naturaleza asimétrica de la agudeza visual en la lectura.

acentes durante la lectura. Se basa principalmente en la hipótesis ojo-mente, que asume que aquello que se fija es lo que se está procesando cognitivamente y que la cantidad de tiempo dedicado a fijar una palabra o región refleja el esfuerzo cognitivo necesario para procesarla (Just and Carpenter (1980), Rayner et al. (2012)). Cuando el texto es más complejo, la duración de las fijaciones aumenta y las sacadas se hacen más cortas.

Como puede verse en la Tabla 1.1, que resume los hallazgos sobre los movimientos oculares durante la lectura, hay fuertes efectos de las propiedades léxicas de las palabras sobre la duración de las fijaciones. Palabras más largas generan fijaciones más prolongadas y palabras más frecuentes suelen generar fijaciones más cortas (Rayner, 1998). Asimismo, el contexto puede facilitar la predictibilidad de la próxima palabra: en casos donde el contexto restringe fuertemente el vocabulario posible, los tiempos de fijación tienden a disminuir ya que la palabra puede anticiparse antes de ser fijada. Este proceso se ve influenciado por la información obtenida en la parafovea. Durante el procesamiento parafoveal, logramos captar atributos de longitud y ciertas letras de las próximas palabras. Adicionalmente, una única fijación podría incorporar la próxima o parte de la próxima palabra dentro del rango de la fovea. Esto lleva a que algunas palabras no tengan fijaciones, en cuyo caso se consideran salteadas (*skipped*, en inglés). Cuanto más lejos estén las palabras de la fovea, más difíciles serán de captar, ya que más borrosa es la información capturada por la parafovea. Esto implica que solo hay una región acotada del campo visual en la cual es posible obtener información antes de necesitar otra fijación.

Por otro lado, las sacadas hacia atrás (es decir, hacia partes del texto ya pasadas) son denominadas regresiones. Estas pueden tener una longitud variable, dependiendo de su causa. Una regresión corta, de un par de palabras, puede deberse a una sacada demasiado larga que saltó palabras. Una regresión más larga, que abarca múltiples líneas, podría indicar una re-lectura para captar un mejor contexto.

Factor	Procesamiento foveal	Procesamiento parafoveal
<i>Decodificación ortográfica y fonológica</i> (Identificación de letras y activación de fonemas correspondientes)	Sí	Sí
<i>Decodificación morfológica</i> (Identificación de morfemas de una palabra)	Sí	Mixto
<i>Longitud de palabra</i> (Palabras más largas = más procesamiento)	Sí	Sí
<i>Frecuencia de palabra</i> (Palabras encontradas con menos frecuencia = más procesamiento)	Sí	Mixto
<i>Tamaño del entorno</i>	Sí	Mixto
<i>Predictibilidad</i> (Palabra más predecible en contexto = menos procesamiento)	Sí	Mixto
<i>Número de significados de palabra</i> (Palabras con más significados = más procesamiento)	Sí	Mixto
<i>Edad de adquisición (EdA)</i> (Palabras aprendidas más tarde = más procesamiento)	Sí	?
<i>Familiaridad</i> (Palabras menos familiares = más procesamiento)	Sí	?

Tab. 1.1: Factores que han sido investigados con respecto a su habilidad para influir en el procesamiento cuando las palabras están en visión foveal (n) y parafoveal ($n + 1$), donde “sí” indica que afecta el procesamiento, “mixto” que la evidencia es contradictoria y “?”, que no ha sido reportado. Traducido de Conklin et al. (2018).

Las fijaciones no duran siempre lo mismo. Esto se debe a que en algunos casos saltamos palabras o volvemos de una regresión (es decir, estamos leyendo algo que ya fue leído). También una misma palabra puede tener múltiples fijaciones, ya sea porque es muy larga y requiere ser fijada por partes, o porque es difícil o inusual y demanda mayor procesamiento.

1.2 Métricas

Todo lo mencionado anteriormente genera patrones de lectura complejos compuestos por sacadas y fijaciones, cuyo estudio es importante para entender mejor cómo funciona el sistema cognitivo humano. Para estudiar estos patrones se utiliza la tecnología de seguimiento ocular (*eye-tracking*). Esta tecnología mide la posición del ojo en la pantalla a través de cámaras que registran los movimientos oculares, identificando las fijaciones y sacadas, a partir de las cuales es posible calcular un conjunto de métricas que se utilizarán a lo largo de esta tesis. Las principales ventajas del seguimiento ocular radican en que es una tecnología no invasiva que aprovecha el fácil acceso a los ojos para obtener una medida directa del esfuerzo durante una tarea, su precisión temporal y la posibilidad de realizar la medición en un entorno natural (en los experimentos, se lee desde un monitor).

La principal desventaja es la dificultad para delimitar con precisión el momento en que se accede al significado de una palabra o cuándo se integra en el entendimiento de la oración o discurso.




Fig. 1.2: Ejemplo de una oración con región de interés (ROI) sobre 'infectar'. Debajo de la oración se representan los movimientos oculares con fijaciones indicadas por círculos numerados indicando el orden. Debajo tenemos una tabla que indican cuáles fijaciones componen cada métrica, las cuales están divididas como 'tempranas', 'intermedias' y 'tardías'. Traducido de Conklin et al. (2018)

A partir de las mediciones obtenidas del *eye-tracking* se puede calcular la longitud de las sacadas y regresiones, la duración de las fijaciones y las palabras que no tuvieron fijaciones. Con esto se calcula un conjunto de métricas que se utilizarán en el análisis.

Un aspecto importante al estudiar las métricas es que cada una refleja diferentes etapas del procesamiento del lenguaje. Esta clasificación temporal se apoya en dos supuestos centrales del modelo de lectura: la inmediatez del procesamiento y la relación ojo-mente. Según estos, los lectores procesan cada palabra en el momento en que la encuentran, y la duración de la fijación refleja directamente el tiempo necesario para procesarla (Just and Carpenter, 1980). Las mediciones se pueden dividir en tres etapas principales: tempranas, intermedias y tardías. Mientras que las mediciones tempranas se interpretan principalmente como un reflejo altamente automático de reconocimiento de palabras (procesamiento

léxico), las mediciones más tardías reflejan procesos más controlados y conscientes (Inhoff (1984); Staub and Rayner (2007)). De manera general, las mediciones tempranas se enfocan en la primera lectura, mientras que las tardías describen el proceso total y la integración de las palabras en el contexto.

En conjunto, estas métricas permiten una reconstrucción detallada del flujo de procesamiento cognitivo durante la lectura. Por lo tanto, el análisis de los movimientos oculares no solo proporciona información sobre dónde se dirige la atención visual, sino también sobre cómo se desarrolla la comprensión textual y cómo se gestionan las dificultades cognitivas a lo largo del tiempo.

1.2.1 Mediciones tempranas

La primera medición temprana a considerar es *First Fixation Duration* (FFD) o duración de primera fijación, la cual mide la duración de la primera fijación sobre cada palabra. FFD está relacionada con la rapidez con la que nuestro sistema cognitivo accede al significado de una palabra al ser fijada. Es decir, refleja el tiempo requerido para realizar un procesamiento léxico inicial, que puede verse influido por características como la longitud de la palabra o su familiaridad, ya que las palabras más largas requieren más tiempo para ser interpretadas, y las menos familiares demandan un acceso más costoso al léxico mental.

Similar a FFD es *First Pass Reading Time* (FPRT), que mide la suma de todas las fijaciones que recibe una palabra antes de que la mirada se desplace a otra. Algunas palabras pueden necesitar dos o más fijaciones consecutivas, tal como se ejemplifica en la Figura 1.2. En estos casos, FFD solo mide el procesamiento inicial, mientras que FPRT captura el procesamiento completo de la palabra.

La última medición temprana se realiza sobre palabras salteadas. Las palabras salteadas, o que no tienen fijaciones, son aquellas que no se miran directamente. Esto puede ocurrir porque la palabra entró en el rango foveal durante una fijación cercana, o porque los atributos obtenidos parafovealmente (como su longitud) fueron suficientes para anticiparla. Palabras como ‘el’ o ‘la’ son frecuentemente salteadas, ya que el contexto gramatical facilita su anticipación. El *Skipping Rate* de una palabra es la proporción de veces que esta fue salteada a lo largo de varias pruebas. Esta medición no proporciona información sobre el procesamiento particular de un individuo, sino que describe un aspecto de la palabra.

1.2.2 Mediciones intermedias

Las mediciones intermedias están relacionadas con la integración de la palabra al contexto. Esto incluye la resolución de ambigüedades e inconsistencias inmediatas. La primera de estas mediciones intermedias es *Regression Path Duration*, que mide todas las fijaciones, desde la primera fijación de una palabra hasta la fijación que avance la lectura a la derecha. Es decir, incluye las primeras fijaciones, regresiones originadas en esta palabra y cualquier fijación posterior antes de continuar con la próxima palabra en la oración. *Regression Path Duration* capta el procesamiento total de la incorporación de la nueva palabra al resto del texto y la resolución de conflictos. Otra medida intermedia es *Regression Rate*, es decir, la proporción de regresiones que tuvo una palabra en varias pruebas. Similar al *Skipping Rate*, esta medida no brinda información sobre un sujeto particular y su método de lectura, sino que ofrece una descripción de la palabra y su complejidad.

1.2.3 Mediciones tardías

Por último, las mediciones tardías. Se relacionan con la integración global del significado y la revisión del texto completo, es decir, estas métricas incluyen fijaciones ocurridas luego de haber continuado con la palabra siguiente. En la Figura 1.2 se observa que casi todas las mediciones tardías incluyen la duración de la fijación nueve, que ocurre por una regresión posterior. *Total Reading Time* es la duración de todas las fijaciones en una palabra, incluyendo regresiones provenientes de palabras posteriores; esta abarca el procesamiento total de la palabra en el texto. Similar a esta medición es *Fixation Count*, que mide la cantidad total de fijaciones realizadas sobre una palabra a lo largo de una prueba.

Por otra parte, *Second Pass Reading Time* se refiere al tiempo total de fijaciones sobre una palabra durante las re-lecturas únicamente, por lo que no incluye las fijaciones que se utilizan para el cálculo de FPRT. Finalmente, *Re-Reading Time* mide específicamente la duración de las fijaciones pertenecientes al *Regression Path* sin las fijaciones iniciales, proporcionando información clave sobre los procesos de re-análisis o re-evaluación durante la lectura.

Entre estas variables queda claro que las mediciones iniciales representan la percepción aislada de la palabra, las mediciones intermedias representan la incorporación de la palabra junto con la resolución de conflictos si existiesen, y las finales representan la integración total de las palabras leídas. Es por esto que las métricas tardías están más influidas por las propiedades sintácticas y contextuales, las cuales incrementan la duración de las fijaciones en una palabra o región crítica, y también pueden causar más regresiones al contexto previo dado que el lector se ve forzado a re-evaluar el análisis inicial (Frazier and Rayner, 1982). Por otro lado, las variables léxicas son la influencia primaria sobre la duración de las primeras fijaciones (Staub and Rayner, 2007). Este conjunto de mediciones es clave para entender cómo las personas acceden, integran y corrigen información durante la lectura.

1.3 Factores que determinan la duración de las fijaciones oculares

Los atributos principales que determinan la duración de una fijación son la longitud y la frecuencia de la palabra en el lenguaje. No obstante, esta última es imposible de cuantificar, por lo que se suele utilizar la frecuencia de aparición de la palabra en un corpus de texto como aproximación. En la Figura 1.3 se observa cómo la longitud de la palabra (a) y la frecuencia (b) afectan la duración de fijación. Esto se debe a que, durante las fijaciones, se busca identificar y decodificar la palabra. Una mayor cantidad de símbolos a decodificar requiere mayor tiempo de procesamiento, mientras que una mayor frecuencia de la palabra reduce el tiempo de identificación y la subsiguiente decodificación (Bianchi, 2014).

Los efectos de la predictibilidad sobre la lectura son bien conocidos. Uno de ellos es la relación entre la predictibilidad de la palabra y las primeras fijaciones, con palabras más predecibles generando fijaciones más cortas o siendo más comúnmente saltadas.

En un trabajo previo de Bianchi et al. (2020), se evaluó cómo técnicas de embedding (como Latent Semantic Analysis, Word2Vec y FastText) y modelos de N-gram estiman la predictibilidad humana de una palabra. Sin embargo, para poder realizar este análisis, es necesario contar con datos de predictibilidad humana. Luego, se diseñó una tarea cloze-task online para aumentar al conjunto de datos con esta variable (Taylor, 1953).

Otro aspecto que impacta en el proceso inicial es la complejidad de la palabra. Si bien no existe una medida directa de la complejidad de una palabra, medir la proporción de




Fig. 1.3: (a) Duración de las fijaciones con respecto a la longitud de las palabras separado en tres grupos etarios (Zoccolotti, 2005) (b) Duración de las fijaciones en función de la frecuencia de las palabras (Carbajal, 2013)

sujetos que necesitaron realizar una regresión (*Regression Rate*) al leerla permite describir una parte de la complejidad de integración de la palabra al contexto previo.

1.4 Fatiga y la lectura

Uno de los ámbitos donde se ha estudiado el efecto de la fatiga es la aviación. (McCulloch, 2007) discuten las causas y consecuencias de la fatiga, demostrando que sujetos fatigados presentan un menor rendimiento en tareas generales, menor atención y menor concentración. No obstante, el efecto de la fatiga en el ámbito de la lectura se mantiene poco estudiado. Dada la establecida relación entre los movimientos oculares durante la lectura y el procesamiento cognitivo del lenguaje, es esperable que mayores niveles de fatiga (que han demostrado impactar la vigilancia y atención) se reflejen en las medidas oculares.

Según Seoane et al. (2020), sujetos privados de sueño durante 36 horas continuas, al ser sometidos a una tarea incidental de codificación de memoria con conjuntos de palabras de distinta valencia emocional (negativas, positivas y neutras), mostraron una retención de apenas el 40% en comparación con los controles que habían dormido con normalidad. Adicionalmente, Seoane et al. (2020) infiere que la fatiga genera confusión, lo que debería impactar en la duración de fijaciones, dado que eleva la dificultad de decodificar la palabra así como de retenerla e incorporarla al contexto.

En este trabajo, se busca investigar cómo cambian los patrones de lectura con la fatiga en métricas oculares como la *First-Fixation Duration* (FFD) y el *First-Pass Reading Time* (FPRT), ya que estas medidas capturan los primeros momentos del procesamiento visual y semántico de cada palabra y permiten observar cómo la fatiga influye sobre el procesamiento durante la lectura. Este enfoque busca no solo cuantificar el efecto de la fatiga en el comportamiento lector, sino también aportar evidencia sobre cómo las condiciones cognitivas modulan el acceso y procesamiento de la información textual en tiempo real.

2. Objetivos

La presente tesis tiene como objetivo general investigar cómo la estructura del lenguaje, la predictibilidad de las palabras y el estado cognitivo del lector (fatiga) influyen en los movimientos oculares durante la lectura de texto natural. Para esto se utilizarán métricas de *eye-tracking* y modelos lineales mixtos. El procesamiento léxico es un fenómeno complejo, y una mejor comprensión de estos efectos permitirá que sean considerados en estudios futuros. Específicamente, podrían incorporarse como factor en modelos predictivos de lectura o como variable explicativa de las discrepancias observadas entre participantes en tareas de lectura prolongada.

2.1 Objetivos particulares

1. **Identificación de factores que influyen en la lectura:** El primer objetivo será identificar los factores textuales y posicionales que explican la variabilidad en las métricas de movimientos oculares tempranas, específicamente *First Fixation Duration* (FFD), *First Pass Reading Time* (FPRT) y *Skipped* (si la palabra es o no saltada). Se determinará la significancia de los factores textuales y sus interacciones, que se utilizarán como punto de partida para evaluar cómo la fatiga y la predictibilidad afectan a estas tres métricas. Adicionalmente, este paso brindará una ventana al funcionamiento cognitivo durante la lectura, lo cual permitirá entender mejor los procesos internos que se discutirán durante los análisis de los efectos de fatiga y predictibilidad sobre los movimientos oculares.
2. **Fatiga basal:** El segundo objetivo será evaluar el impacto de la fatiga basal del lector en las métricas de movimientos oculares, analizando específicamente cómo la cantidad de horas dormidas y el tiempo de vigilia afectan el procesamiento temprano del texto. Se espera que estos factores de fatiga se reflejen particularmente en las medidas de FFD y FPRT, proporcionando evidencia sobre cómo el estado cognitivo del lector modula los procesos de lectura a nivel fisiológico. Se espera que esto lleve a que los efectos de la fatiga sean considerados en estudios posteriores y sirva como punto de referencia para futuros análisis.
3. **Estudio de la predictibilidad:** El tercer y último objetivo será calcular la predictibilidad de las palabras de los textos utilizados y evaluar cómo su incorporación afecta a los modelos entrenados. Los hallazgos sobre predictibilidad podrían contribuir a la validación de modelos de lenguaje, dado que los tiempos de lectura humanos sirven como benchmark para evaluar qué tan bien estos modelos capturan las expectativas lingüísticas de los hablantes. Adicionalmente, se expandirá el corpus original agregando la predictibilidad de las palabras.

3. Métodos

3.1 Datos

3.1.1 Sobre los sujetos

El dataset está compuesto por mediciones de movimientos oculares de 76 personas, 44 de las cuales fueron mujeres, 31 hombres y una sin género especificado, todos hispanohablantes nativos. El grupo de participantes estaba compuesto mayormente por estudiantes universitarios con una edad media de 23,5 años y un rango intercuartil de 4,8.

3.1.2 Sobre los textos

Los textos leídos están compuestos de veinte historias cortas autocontenidas en español. Las historias tienen un promedio de tiempo de lectura de 3 minutos y un promedio de 660 palabras. La más corta tiene 544 palabras y la más larga posee 1066 palabras (Travi et al., 2026). Cinco de las historias fueron extraídas de blogs argentinos en línea y las otras quince de “100 covers de cuentos clásicos” (Casciari, 2021), que consta de relatos clásicos simplificados, reescritos y, en caso de pertenecer a otro idioma, traducidos por Hernán Casciari. Con esta selección se buscó obtener diversidad de estilo literario, manteniendo una dificultad constante.

El criterio de selección se basó en que los textos tuvieran entre 400 y 1500 palabras, que no tuvieran fechas escritas y que minimizaran: los diálogos; los caracteres poco frecuentes; las oraciones muy cortas o muy largas (menos de 6 palabras o más de 29 respectivamente); y palabras poco frecuentes (menos de 100 apariciones en la base de subtítulos latinoamericanos EsPal Duchon et al. (2013)). El objetivo de este criterio fue minimizar los factores de confusión en las medidas del *eye-tracking* y, así, maximizar la calidad de la información obtenida.

3.1.3 Ejecución

El experimento fue llevado a cabo en una habitación oscura con un EyeLink 1000 (SR Research, Canadá) que registra los movimientos oculares a 1000 Hz. La pantalla tenía una resolución de 1920×1080 y los participantes se sentaron a 55 cm con la cabeza apoyada en un soporte para limitar el movimiento. Los textos se formatearon usando Courier New, tamaño 24 y con el texto negro sobre gris. Se usó un interlineado de 55 píxeles, un margen izquierdo de 280px y uno superior de 185px, lo que permite hasta catorce líneas por pantalla. Cada historia se repartió en cuatro a seis pantallas, según la longitud de la historia, y los lectores podían avanzar o retroceder con las flechas del teclado.

Al empezar, se les pidió que leyeran con atención para luego responder preguntas de comprensión. Tres meses después del inicio del experimento, se comenzó a registrar la hora a la que los participantes se fueron a dormir y se levantaron el día de la prueba, para poder estimar su grado de fatiga.

Cada cuento funcionó como un ítem experimental. Antes de mostrarlo se calibró el *eye-tracker* y, tanto antes como después de la lectura, se les pedía fijar la vista en una grilla de

Historia	Autor	Participantes	Palabras	Fijaciones
Educación para escalar y bucear	Andrés Rieznik	47	599	27797
La noche de los feos	Mario Benedetti	49	544	25774
Rubí y el lago danzante	Marcelo Cohen	53	641	30216
El golpe de gracia	Ambrose Bierce	50	602	27629
La canción que cantábamos todos los días	Luciano Lamberti	53	620	28299
Una rosa para Emilia	William Faulkner	55	643	33946
La máscara de la Muerte Roja	Edgar Allan Poe	47	572	26641
Wakefield	Nathaniel Hawthorne	52	693	31610
Buenos Aires	Hernán Casciari	47	607	28813
Ahora debería reírme, si no estuviera muerto	Angela Carter	53	606	25629
El almohadón de plumas	Horacio Quiroga	56	579	28063
La lluvia de fuego	Leopoldo Lugones	53	640	30960
El espejo	Haruki Murakami	56	628	29851
La salud de los enfermos	Julio Cortázar	56	667	34486
La gallina degollada	Horacio Quiroga	51	659	30188
Cómo funciona caminar en la nieve	Valentín Muro	45	1066	47302
Las fotografías	Silvina Ocampo	46	618	26686
La de la Obsesión por la Patineta	Javier Gallo	51	579	29200
Embarrar la magia	Facundo Alvarez Heduán	49	683	34749
Cómo funcionan los bolsillos	Valentín Muro	46	972	45815
Total		1015	13218	623654
Promedio		50.75	660.9	31182.7
Máximo		56	1066	47302
Mínimo		45	544	25629

Tab. 3.1: Estadísticas de lectura por historia

nueve puntos (centro y márgenes) para validar la calibración. Las historias se ordenaron de menor a mayor cantidad de palabras poco frecuentes, caracteres poco frecuentes y oraciones muy cortas o muy largas. Luego se armaron cuatro bloques de cinco ítems y se aleatorizó cada bloque para cada participante. El estudio se dividió en dos sesiones de diez ensayos (dos bloques).

Una vez respondidas las preguntas de comprensión, los sujetos pasaron a una tarea de asociación libre: se les mostró una palabra y escribían la primera que se les ocurría, con el objetivo de eliminar cualquier sesgo residual de la lectura antes de seguir. Solo cuando indicaban que estaban listos podían pasar al siguiente ensayo.

3.2 Procesamiento de datos de movimientos oculares

3.2.1 Preprocesamiento

Las fijaciones y sacadas de ambos ojos fueron detectadas usando el algoritmo incorporado de Eyelink. A cada fijación se le asignó un identificador único, numerado de forma secuencial a lo largo de todo el ensayo. Las primeras y últimas fijaciones de cada pantalla fueron descartadas automáticamente, al igual que las fijaciones muy cortas o muy largas (menos de 50 ms o más de 1000 ms), ya que tendían a corresponder a detecciones erróneas o a momentos en que el participante no estaba prestando atención (Travi et al., 2026).

Para calcular las métricas de *eye-tracking* es necesario determinar qué fijaciones corresponden a cada palabra. Se procesaron los datos manualmente: en cada pantalla, las fijaciones fueron encerradas entre líneas horizontales trazadas a mano. A menudo se presentaba una descalibración en el eje vertical, y las fijaciones se ajustaban manualmente en esa dirección. Si la calibración era muy deficiente, se excluía el ensayo del análisis. En algunos casos, los participantes volvían accidentalmente a una pantalla anterior (lo cual




Fig. 3.1: Ejemplo de diseño del experimento

se manifestaba como fijaciones dispersas en posiciones aleatorias de la pantalla) y estas también fueron eliminadas. Luego del procesamiento manual, se descartaron 111 de los 1126 ensayos por mala calibración.

3.2.2 Cálculo de métricas

Al leer, cuando pasamos de una línea a la siguiente, los ojos generalmente no aterrizan con precisión sobre la primera palabra de la nueva línea, por lo que se realizan algunas fijaciones adicionales para corregir la posición ocular. Estas se conocen como *return sweeps* y se consideran errores de sobreestimación del próximo punto de fijación, por lo que fueron descartadas. Se identificaron los *return sweeps* como toda sacada a la izquierda luego de la primera fijación de una línea. También se prestó especial atención a las fijaciones resultantes de volver a una pantalla vista previamente. Esas fijaciones fueron numeradas comenzando desde el último número de fijaciones registrado en esa pantalla.

Luego de realizar estos pasos, las fijaciones correspondientes a una palabra específica son aquellas cuyas coordenadas horizontales caen dentro del espacio en blanco que la rodea. El espacio en blanco derecho se excluye, es decir, se considera parte de la siguiente palabra, ya que la lectura se realiza de izquierda a derecha.

Se aplicaron criterios de exclusión al calcular las métricas de *eye-tracking* de cada palabra del ensayo. No se calcularon métricas si la palabra era la primera o la última de una oración, la primera o la última de una línea, o si contenía alguno de los siguientes caracteres: ‘¿’, ‘?’, ‘¡’, ‘!’, ‘.’, ‘,’ ‘1’, ‘2’, ‘3’, ‘4’, ‘5’, ‘6’, ‘7’, ‘8’, ‘9’, ‘0’. Es importante destacar que estos criterios se aplican a nivel de ítem, lo que significa que las palabras excluidas son las mismas en todos los ensayos.

Para definir y calcular las métricas con las que se trabajará, se definió una regresión como cualquier fijación sobre una palabra luego de haber salido de ella, ya sea hacia la derecha o hacia la izquierda. “Salir” de una palabra incluye también omitirla. Bajo esta definición, la duración de la primera fijación (FFD), la duración de fijación única (SFD) y la duración de mirada (FPRT) solo se definen si una fijación entra en la palabra desde

una región anterior del texto antes de que ocurra una fijación en una región posterior de esa misma pantalla. Las fijaciones que provienen de pantallas previamente vistas se consideran regresiones si la palabra en la que aterrizan, o cualquiera de las siguientes en la pantalla, ya había sido fijada.

La idea se *incubó* rápidamente entre la gente




Fig. 3.2: Ejemplo de fijaciones durante la lectura

Finalmente, se calculó un conjunto de atributos adicionales a partir de la posición de las palabras y sus fijaciones. *Fixation Count* (FC) cuenta la cantidad de fijaciones que tuvo una palabra en particular. Tomando como ejemplo la palabra “incubó” de la Figura 3.2, el FC se calcula contando las cuatro fijaciones que tiene la palabra. En caso de no tener fijaciones, se considera *Skipped*, por ejemplo la palabra “La” y “se” de la figura anterior. Para calcular el *Skipping Rate*, se contó la cantidad de pruebas que marcaron a la palabra como *Skipped* y se la dividió por el total de pruebas realizadas de esa historia. Similar a *Skipped*, *Regression Count* (RC) cuenta la cantidad de regresiones de una palabra a través de las pruebas. Al dividir el RC por la cantidad total de pruebas, se obtiene el *Regression Rate* (RR).

First Fixation Duration (FFD), como se mencionó en la introducción, mide la duración de la primera fijación de la palabra. En la imagen anterior, la palabra “incubó” tiene tres fijaciones; sin embargo, FFD es solo la duración de la fijación 2. Por otro lado, *First Pass Reading Time* (FPRT) mide la suma de las primeras fijaciones antes de que la mirada pase a otra palabra. En el caso de la palabra ejemplo, sería la suma de las duraciones de las fijaciones 2 y 3. Mientras que *Total Reading Time* (TRT) mide todas las fijaciones; en este caso, 2, 3 y 5 sumarían el TRT de “incubó”. *Second Pass Reading Time* es toda relectura sobre una palabra y se obtiene restando FPRT a TRT.

Regression Path Duration (RPD) mide el camino desde una palabra con regresión hasta que se realiza una fijación en una palabra posterior. En este caso, el camino de regresión que empieza en la palabra ejemplo tiene un RPD igual a la suma de las fijaciones 2, 3, 4 y 5. A RPD se le resta el FPRT para obtener el *Re-Reading*, o el tiempo en el que una persona relee antes de continuar la lectura.

3.3 Métricas calculadas sobre las palabras

Las métricas calculadas en la sección anterior describen el comportamiento ocular durante la lectura. Adicionalmente, se consideran atributos propios de las palabras, como la longitud y la frecuencia o el posicionamiento de la palabra en el texto.

Se calculó el índice de cada palabra dentro de la historia, el índice de cada palabra dentro de cada oración y el índice de cada palabra dentro de cada pantalla. Estos índices fueron normalizados entre cero y uno para estandarizar el valor máximo.

Finalmente, se calculó la longitud de cada palabra junto con su frecuencia en el lenguaje. Para la longitud se utilizó la inversa para obtener un valor normalizado entre cero y uno. La frecuencia se obtuvo de la base de subtítulos latinoamericanos EsPal (Duchon et al., 2013). Una vez obtenida la frecuencia, se normalizó calculando el logaritmo natural de la frecuencia (Fórmula 3.1).

$$word_freq_i = \ln(espal_freq[word_i]) \quad (3.1)$$

3.4 Modelos lineales mixtos

Los modelos lineales son una herramienta para estimar cómo una variable dependiente (por ejemplo, el tiempo de lectura) varía en función de uno o más predictores (como la longitud de la palabra o el tipo de oración). La idea detrás de los modelos lineales es que existe una relación lineal entre las variables independientes y la variable dependiente. La Fórmula 3.2 y la Fórmula 3.3 son ejemplos de cómo una variable dependiente (tiempo de lectura) es estimada a partir de una o dos variables independientes.

$$\text{tiempo_lectura} \sim \text{longitud_palabra} \quad (3.2)$$

$$\text{tiempo_lectura} \sim \text{longitud_palabra} + \text{fluidez_lector} \quad (3.3)$$

Sin embargo, los modelos lineales presentan limitaciones importantes cuando múltiples observaciones provienen de un mismo sujeto o estímulo, por ejemplo múltiples lecturas hechas por una misma persona. En estos casos, las respuestas tienden a estar correlacionadas, lo que contradice el supuesto de independencia entre observaciones. Esto puede llevar a errores en la estimación de efectos, a una sobrestimación de la significancia estadística y a una reducción de la generalización de los resultados.

Los modelos lineales mixtos (LMM) superan esta limitación al incorporar efectos aleatorios, lo que permite una estimación más precisa y generalizable de los efectos experimentales. Una fórmula típica que ilustra la estructura de un LMM es:

$$FFD \sim word_len \times word_freq + word_idx + (1 \mid subj) \quad (3.4)$$

En este ejemplo, FFD (*First Fixation Duration*) es la variable dependiente, la variable que buscamos explicar. Los términos *word_len*, *word_freq* y *word_idx* son efectos fijos: predictores que potencialmente influyen sobre la variable dependiente. El término *word_len* $\times$ *word_freq* representa una interacción entre *word_len* y *word_freq*.

Una interacción entre dos variables independientes significa que se considera el efecto combinado de ambas variables sobre la variable dependiente. En otras palabras, se considera que la interacción no es aditiva, sino que también cuenta con un factor multiplicativo. Entre las variables independientes que se van a usar están la longitud de la palabra y la frecuencia de la palabra en el lenguaje. Estas variables tienen una correlación conocida que se busca capturar mediante una interacción. La ley de abreviación de Zipf establece la existencia de una correlación negativa entre la longitud y la frecuencia de una palabra (Zipf, 1949). Adicionalmente, Zipf hipotetiza que esto se debe al principio del menor esfuerzo y a la necesidad de una comunicación correcta (Zipf, 1949), lo que lleva a que se usen palabras más cortas para las más frecuentes.

El operador de suma (+) indica que cada término se suma al modelo como un efecto separado (sin interacción). En nuestro ejemplo tenemos a *word_idx* que representa la posición de la palabra en un texto. Esta variable no tiene relación con la longitud o frecuencia de una palabra las variables que describen una palabra en relación con su contexto son independientes de las que la describen léxicamente.

Por otro lado, (1 | *subj*) indica que existe una aleatoriedad debida a los participantes o sujetos que no es parte de la selección de propiedades que resultan de interés para el análisis. Distintas personas tienen sus propios patrones de lectura que generan una variabilidad que ningún descriptor de la palabra puede explicar. A diferencia de los efectos fijos, que son constantes y generalizables, los efectos aleatorios son tratados como muestras de una distribución normal y no se interpretan individualmente, sino como fuentes de varianza.

La estimación de los parámetros del modelo se basa en métodos de máxima verosimilitud (ML) o verosimilitud restringida (REML), que permiten descomponer la varianza atribuible a los efectos fijos y aleatorios. Para evaluar la significancia de los efectos fijos, se suelen utilizar p-valores, obtenidos mediante simulaciones, aproximaciones numéricas o comparaciones entre modelos anidados. El p-valor es la probabilidad de obtener los resultados observados dado que la hipótesis nula es verdadera. Para considerar que una variable independiente es significativa en el modelo, se requiere que el p-valor esté por debajo de 0.05. De esta forma, se establece que hay evidencia suficiente para rechazar la hipótesis nula y considerar que la variable tiene un efecto real sobre la variable dependiente.

Los criterios de información como el AIC (Akaike Information Criterion) son útiles para comparar modelos. Esta métrica penaliza la complejidad del modelo (número de parámetros), de modo que un valor más bajo indica un mejor equilibrio entre ajuste y parsimonia. Al comparar modelos se utilizará el AIC para elegir el modelo que mejor se ajusta a los datos sin sobrecargarlo de variables independientes. Por último, los modelos mixtos también reportan las varianzas de los efectos aleatorios, lo que permite conocer cuánta variabilidad se atribuye a sujetos o ítems, y evaluar si incluir estos efectos mejora sustancialmente la calidad del modelo.

En conjunto, los modelos lineales mixtos ofrecen una estructura poderosa para analizar datos experimentales complejos, permitiendo capturar tanto las tendencias generales de la población como la variabilidad específica de los elementos individuales que componen la muestra.

3.4.1 Modelos a ajustar

Para el desarrollo de este estudio se utilizará como entrada el conjunto de todas las palabras con sus respectivas medidas oculares. Entre estas se incluyen las variables dependiente: FFD, FPRT y *Skipped*; y las variables independientes de posición: el índice de la palabra en el texto, el índice de la palabra en la oración y el índice de la palabra en la pantalla. Además, se incluyen el *Regression Rate* y la fatiga como atributos adicionales.

Para la búsqueda de los LMM que mejor estimen las variables dependientes (VD) FFD, FPRT y *Skipped*, se hará una búsqueda top-down en la cual se parte de una fórmula que abarca todas las variables independientes y, gradualmente, a través de la evaluación de la significancia de las variables independientes y el AIC del modelo, se determina qué variables eliminar de la fórmula, hasta encontrar una fórmula con solo variables independientes significativas.

$$\begin{aligned}
VD \sim & word_len \times word_freq + word_idx \\
& + sentence_pos + sentence_pos_qrt + RR \\
& + screen_pos + (1 \mid subj) + (1 \mid item)
\end{aligned} \tag{3.5}$$

La Fórmula 3.5 es la base de los modelos durante la búsqueda. Esta fórmula es muy similar a Fórmula 3.4 pero con un efecto aleatorio adicional *item* que representa una instancia de una palabra en un texto. Esta variable, al igual que sujeto, aporta variabilidad a los datos.

Adicionalmente, la fórmula base posee la posición de la palabra en la oración (*sentence_pos*), la posición de la palabra en la oración al cuadrado (*sentence_pos_sqrt*), la posición de la palabra en la pantalla (*screen_pos*) y finalmente el *regression rate* (RR).

Word_idx, *sentence_pos*, *sentence_pos_sqrt* y *screen_pos* se agregan para capturar los patrones de lectura asociados al orden de las palabras. Al principio de la oración, el lector comienza a incrementar su velocidad de lectura, mientras que al final se ralentiza para incorporar lo leído, por lo que *sentence_pos_sqrt* intenta captar ese comportamiento cuadrático. *Screen_pos* es la única de estas variables exclusiva del experimento que formó el conjunto de datos, ya que se decidió dividir las historias en cuatro a seis pantallas. *Regression rate* se determina a partir de las métricas de los usuarios y refleja la complejidad de la palabra, lo que debería afectar las primeras fijaciones.

Para correr estos modelos se usa el paquete lme4 del lenguaje R a través de la librería de Python (versión 3.12) pymer4 (versión 0.8.2). Los modelos se corrieron en una computadora con un procesador Intel i7 6800K de seis núcleos corriendo a 3.4 GHz y 16 GB de RAM DDR4.

3.5 Fatiga

Para calcular el valor de fatiga se siguió el cálculo propuesto por McCulloch (2007), que asigna puntos a tres componentes distintos: horas de sueño en las últimas 24 horas, horas de sueño en las últimas 48 horas y horas despiertas desde la última vez que durmió.

En el experimento, se les preguntó a los participantes la cantidad de horas dormidas en el último período de sueño y la cantidad de horas transcurridas desde que se despertaron. Estos datos fueron recolectados al principio de cada sesión para 23 participantes (en un total de 330 ensayos) (Travi et al., 2026). Como en este caso no se cuenta con la información del sueño en las últimas 48 horas, este componente se omitió.

El primer componente de los restantes, denominado “horas de sueño en las últimas 24 horas”, evalúa si la duración del último período de sueño fue inferior a cinco horas. En caso afirmativo, se asignan puntos en función del déficit de sueño: se suman 4 puntos por cada hora completa por debajo de ese umbral, 2 puntos por cada media hora adicional, y 1 punto por cada cuarto de hora. Por ejemplo, si una persona durmió 3 horas y media, acumularía 6 puntos (1 hora completa de déficit = 4 puntos, más media hora = 2 puntos, total = 6 puntos). Si la persona durmió 5 horas o más, este componente no suma puntaje.

El segundo componente, denominado “horas de vigilia”, considera la cantidad de tiempo transcurrido desde el despertar. Para calcularlo, se multiplica por dos la cantidad de horas dormidas en el último período de sueño, y luego se suma 1 punto por cada hora que exceda ese valor. Por ejemplo, si una persona durmió 5 horas y lleva 11 horas despierta, se realiza el cálculo $5 \times 2 = 10$, y como 11 excede ese valor en una hora, se suma

1 punto. En cambio, si durmió 6 horas y ha estado despierta solo 5, el resultado sería $6 \times 2 = 12$, y como las horas de vigilia no superan este umbral, no se asignan puntos.

La suma de ambos componentes conforma el puntaje (*score*) final de fatiga, que refleja de forma simple el estado de cansancio de una persona a partir de dos variables clave: la cantidad de horas dormidas y el tiempo de vigilia.

$$\begin{aligned} VD \sim & \textit{fatigue} \times (\textit{word_len} \times \textit{word_freq} + \textit{word_idx} \\ & + \textit{sentence_pos} + \textit{sentence_pos_sqrt} + RR \\ & + \textit{screen_pos}) + (1 \mid \textit{subj}) + (1 \mid \textit{item}) \end{aligned} \quad (3.6)$$

$$\begin{aligned} VD \sim & \textit{fatigue} \times (\textit{word_len} \times \textit{word_freq} + \textit{word_idx} \\ & + \textit{sentence_pos} + \textit{sentence_pos_sqrt} + RR) \\ & + \textit{screen_pos} + (1 \mid \textit{subj}) + (1 \mid \textit{item}) \end{aligned} \quad (3.7)$$

$$\begin{aligned} VD \sim & \textit{fatigue} \times (\textit{word_len} \times \textit{word_freq} + \textit{word_idx} \\ & + \textit{sentence_pos} + \textit{sentence_pos_sqrt} + RR) \\ & + (1 \mid \textit{subj}) + (1 \mid \textit{item}) \end{aligned} \quad (3.8)$$

Para el ajuste del modelo, se hará un proceso similar a la sección anterior, pero agregando fatiga como una interacción con el resto de las variables independientes como en Fórmula 3.6. Antes de quitar una variable del modelo, primero se la remueve de la interacción con fatiga, como en Fórmula 3.7, donde *screen_pos* queda fuera de la interacción. Si en la nueva fórmula la variable resulta significativa y el AIC se reduce, se continúa analizando la próxima variable no significativa. De lo contrario, se remueve la variable completamente del modelo, como se muestra en la Fórmula 3.8.


$$\begin{aligned} VD \sim & \textit{fatiga} \times (\textit{word_len} \times \textit{word_freq} + \textit{word_idx} + \textit{sentence_pos}) \\ & + \textit{screen_pos} + RR + (1 \mid \textit{item}) + (1 \mid \textit{subj}) \end{aligned} \quad (3.9)$$

Con esta metodología se evaluará cómo la fatiga interactúa con las otras variables independientes, lo que permitirá formular hipótesis sobre las interacciones restantes. El modelo final será similar a la Fórmula 3.9, donde algunas variables independientes permanecen dentro de la interacción con fatiga, otras quedan fuera de la interacción y algunas no forman parte de la fórmula final.

3.6 Predictibilidad

Con el objetivo de incorporar la predictibilidad léxica como variable en los modelos lineales mixtos, se diseñó un experimento en línea para estimar, palabra por palabra, cuán predecible es cada palabra dentro de las historias. Esta información permite mejorar el poder explicativo de los modelos al introducir una medida de relevancia cognitiva y lingüística, según el trabajo previo de Fernández et al. (2013).

El experimento consiste en una página web donde los usuarios acceden para leer las mismas 20 historias utilizadas en el corpus principal. A lo largo de la lectura, deben



Ayer le di de comer a mi

Ayer le di de comer a mi

Ayer le di de comer a mi perro y él se puso muy

Fig. 3.3: Etapa de prueba del experimento web para la búsqueda de predictibilidad de la palabra

completar palabras faltantes en secuencias específicas, simulando una tarea de predicción tipo cloze. Esta técnica, ampliamente utilizada en psicolingüística, consiste en presentar un texto con palabras omitidas que el participante debe completar basándose en el contexto previo, lo que permite medir la predictibilidad léxica de forma empírica. Antes de comenzar, cada usuario completaba un ejemplo con dos secuencias guiadas, lo que permitía familiarizarse con el formato de la tarea y minimizar posibles confusiones sobre la dinámica. La secuencia que se utiliza es “Ayer le di de comer a mi perro y él se puso muy feliz”, donde los participantes primero predicen la palabra perro y luego feliz, tal como lo muestra la Figura 3.3.

A diferencia del diseño original usado para recolectar las medidas oculares, en esta versión online cada historia se presentaba como una única pantalla que se expandía dinámicamente a medida que el usuario completaba palabras faltantes. Las historias estaban divididas en segmentos de entre 25 y 30 palabras, y al final de cada segmento se le solicitaba al participante que predijera la última palabra. Los contextos previos siempre se mantenían visibles, de modo que el texto crecía en pantalla acumulando información, lo cual simulaba condiciones naturales de procesamiento textual lineal.

La primera secuencia de cada historia podía tener una longitud mínima de una palabra, es decir, se podía solicitar la predicción de la primera palabra de la historia, lo que permitía capturar la predictibilidad incluso con mínimo contexto. En total, cada usuario completaba entre 20 y 35 predicciones, dependiendo de la longitud de las historias. Por cada intento, se registró la palabra ingresada, el índice correspondiente dentro de la historia y el identificador único del relato, lo que permite luego mapear cada respuesta a una posición específica del corpus y así derivar una medida de predictibilidad empírica para cada palabra.

Para calcular la predictibilidad de las palabras se estimó que se necesitan 30 predicciones por palabra. Dado que las historias tienen entre 600 y 1200 palabras, se estiman necesarios entre 500 y 1000 participantes por historia, asumiendo una distribución uniforme en la predicción. El experimento sigue recolectando predicciones para poder alcanzar la cantidad deseada de predicciones por palabra.

4. Resultados

Se buscaron los modelos que mejor predicen FFD, FPRT y *Skipped* según el dataset descrito en la Sección 3.1. Para esto se utilizó una metodología top-down donde se ajustó un modelo lineal mixto por variable dependiente. De este ajuste se obtiene el p-valor de cada efecto fijo. En caso de que una o más variables presenten un efecto no significativo ($p\text{-valor} > 0.05$), se remueven individualmente según su p-valor, empezando por el más alto. En la subsección siguiente (Sección 4.1), se analizarán los efectos de las variables independientes sobre las tres variables dependientes una por una. Mientras que en la subsección posterior (Sección 4.2) se analizarán los efectos de la inclusión de fatiga como nueva variable independiente.

Para predecir las tres variables dependientes se utilizarán variables que describan únicamente las palabras. Esto implica que no se incluyeron variables que dependan de una persona en particular, como *fixation count*, ni mediciones intermedias o tardías, ya que una persona no llega a esas etapas de procesamiento antes de realizar las primeras fijaciones o determinar si saltar o no una palabra. Entre estas variables independientes están la longitud de la palabra (*word_len*), la frecuencia de la palabra (*word_freq*), variables de posicionamiento como la posición de la palabra en la historia (*word_idx*), en la oración (*sentence_pos*) y en la pantalla (*screen_pos*). Al empezar a leer una oración, se suele acelerar la lectura dado que se forma un contexto que facilita la predicción de la próxima palabra. En contraposición, al finalizar la oración, los lectores suelen detenerse para terminar de integrar lo leído al resto del contexto; esto produce una desaceleración de la fluidez lectora desde el principio de la oración hacia su fin (Kuperman et al., 2010). Por esto mismo, también se utilizará la variable posición de la palabra en la oración al cuadrado (*sentence_pos_squared*), que intenta representar este patrón parabólico. Finalmente, también se utilizará *regression rate* (RR), que no es una medición temprana ni un atributo perceptible durante la lectura, sino un atributo estadístico de la palabra que describe qué tan seguido se debe realizar una regresión, por lo que está asociada a la complejidad de dicha palabra. No se alcanzó la cantidad suficiente de participantes por historia en el experimento web (alrededor de 500), por lo que no se incluyó la predictibilidad como variable.

4.1 Modelos sin fatiga

4.1.1 *First Fixation Duration*

First Fixation Duration necesitó dos modelos distintos dado que en la Tabla A1, *sentence_pos* y *sentence_pos_squared* tuvieron efectos no significativos ($p\text{-valor} > 0.05$). Dado que la primera de estas tuvo el p-valor más alto, se quitó para ajustar un segundo modelo. Esto llevó a una redistribución de los pesos, lo que provocó que el efecto de *sentence_pos_squared* se volviera significativo con un p-valor de 0.007. Esto indica que ambas variables capturaban patrones similares, por lo que compartían varianza.

Fuera de este fenómeno, todas las otras variables independientes resultaron significativas. El modelo final para FFD incluye como predictores significativos: longitud de palabra (*word_len*), frecuencia de palabra (*word_freq*), índice de palabra (*word_idx*), posición

	FFD		FPRT		<i>Skipped</i>	
Predictor	p-value	sig.	p-value	sig.	p-value	sig.
(Intercept)	< 0.001	***	< 0.001	***	< 0.001	***
<i>word_len</i>	0.004	**	< 0.001	***	< 0.001	***
<i>word_freq</i>	< 0.001	***	< 0.001	***	< 0.001	***
<i>word_idx</i>	< 0.001	***	< 0.001	***	< 0.001	***
<i>sentence_pos</i>	—	—	< 0.001	***	< 0.001	***
<i>sentence_pos_squared</i>	0.007	**	0.012	*	< 0.001	***
<i>screen_pos</i>	0.001	**	0.001	**	< 0.001	***
RR	< 0.001	***	< 0.001	***	—	—
<i>word_len:word_freq</i>	0.001	***	< 0.001	***	< 0.001	***
AIC	-901217.16		-844072.63		733869.31	

Tab. 4.1: Modelos Finales: Comparación de p-valores y significancia. Valores obtenidos por los modelos de las tablas Tabla A2, Tabla A3 y Tabla A4.

cuadrática en la oración (*sentence_pos_squared*), posición en pantalla (*screen_pos*), tasa de regresión (RR), y la interacción entre longitud y frecuencia de palabra (*word_len:word_freq*). Todos estos predictores muestran efectos estadísticamente significativos en los tiempos de primera fijación, con el modelo alcanzando un AIC de -901217.16, que se usó como AIC base.

El posicionamiento dentro de la pantalla es el único atributo que refleja la estructura del experimento y explica patrones no comunes durante una lectura normal que las otras variables no captan. En el experimento, los participantes podían cambiar entre las distintas pantallas de texto durante la lectura, lo que los limitaba a visualizar un fragmento acotado a la vez, restringiendo la posibilidad de realizar regresiones largas. Esto resulta en patrones peculiares durante el cambio de pantalla. Por esta razón, esta variable tiene una alta significancia estadística.

Similarmente, *Regression Rate* también capta información única acerca de la palabra en relación con el contexto previo, que ninguna de las otras variables independientes puede expresar.

4.1.2 First Pass Reading Time

Para First Pass Reading Time, todos los predictores incluidos en el modelo base (Tabla A3) resultaron estadísticamente significativos. A diferencia del modelo de FFD, no fue necesario realizar iteraciones para remover variables no significativas, lo que sugiere que los predictores captan de forma más directa los patrones de procesamiento en la primera pasada.

La inclusión exitosa de ambos términos de posición en la oración (*sentence_pos* y *sentence_pos_squared*) sugiere que FPRT captura tanto efectos lineales como cuadráticos de la posición de las palabras dentro de las oraciones, reflejando patrones más complejos de procesamiento durante la primera pasada de lectura.

Es esperable que los efectos de las variables independientes tengan una significancia similar a la del modelo de FFD, dado que ambas métricas están muy relacionadas: cuando una palabra tiene una única fijación el FFD coincide con el FPRT; en caso contrario, la palabra tiene múltiples fijaciones y FFD forma parte del cálculo de FPRT.

El resto de las variables independientes muestran efectos significativos ($p < 0.001$), lo cual genera otra diferencia con el modelo de FFD, ya que en este último (Tabla A2) la longitud de la palabra tiene un p-valor de 0.004 y la interacción entre *word_len* y

word_idx de 0.01. El modelo final para FPRT incluye como predictores: longitud de palabra (*word_len*), frecuencia de palabra (*word_freq*), índice de palabra (*word_idx*), posición en la oración (*sentence_pos*), posición cuadrática en la oración (*sentence_pos_squared*), posición en pantalla (*screen_pos*), *Regression Rate* (RR), y la interacción entre longitud y frecuencia (*word_len:word_freq*).

4.1.3 Palabras salteadas

Finalmente, en el modelo para *Skipped*, todas las variables tuvieron efectos significativos con un p-valor menor a 0.001, incluyendo *sentence_pos* y *sentence_pos_squared*, que en el modelo de FFD y FPRT habían presentado p-valores más altos.

4.2 Modelos con fatiga

Predictor	FFD		FPRT	
	p-value	sig.	p-value	sig.
(Intercept)	< 0.001	***	< 0.001	***
<i>fatigue</i>	< 0.001	***	0.015	*
<i>word_len</i>	0.039	*	< 0.001	***
<i>word_freq</i>	< 0.001	***	0.047	*
<i>sentence_pos_squared</i>	0.069	.	0.140	
RR	< 0.001	***	< 0.001	***
<i>word_idx</i>	—	—	0.001	**
<i>sentence_pos</i>	—	—	0.002	**
<i>screen_pos</i>	< 0.001	***	< 0.001	***
<i>word_len:word_freq</i>	< 0.001	***	< 0.001	***
<i>fatigue:word_len</i>	< 0.001	***	0.206	
<i>fatigue:word_freq</i>	0.001	***	0.007	**
<i>fatigue:sentence_pos_squared</i>	0.025	*	0.032	*
<i>fatigue:RR</i>	0.041	*	< 0.001	***
<i>fatigue:word_len:word_freq</i>	0.022	*	0.210	
AIC	98157.11		122191.00	

Tab. 4.2: Modelos de Fatiga Finales: Comparación de p-valores y significancia. Valores obtenidos por los modelos de las tablas Tabla A10 y Tabla A14.

4.2.1 First Fixation Duration

Durante la búsqueda top-down del modelo lineal mixto para *First Fixation Duration*, se necesitaron seis modelos distintos (Anexo 6.2.1). El primero muestra que varias de las interacciones son no significativas y, de forma similar al primer modelo de FFD sin fatiga (Tabla A1), *sentence_pos* y *sentence_pos_squared* también tienen un p-valor alto.

Al igual que en la sección anterior, se comenzó por remover el predictor con p-valor más alto, la interacción entre fatiga y la posición en la pantalla (*fatigue:screen_pos*) con un p-valor de 0.938. Remover esta interacción indica que no hay evidencia de que la fatiga modifique el efecto de la posición en la pantalla sobre la duración de la primera fijación. En otras palabras, el efecto de la posición en la pantalla sobre FFD se mantiene constante independientemente del cansancio del participante.

El segundo y tercer modelo de FFD con fatiga (Tabla A6 y Tabla A7) indican que el posicionamiento de la palabra dentro de la oración (p-valor: 0.946 en el tercer modelo)

junto con su interacción con fatiga (p-valor: 0.761 en el segundo modelo) tienen efectos no significativos, mostrando un paralelismo con el primer modelo de FFD analizado en la sección anterior. Dado que no todos los participantes respondieron las preguntas necesarias para calcular fatiga, se trabaja con un dataset reducido con los datos de participantes con información de fatiga, por lo que existía la posibilidad de que esta interacción se mantuviera debido a un desbalance de datos. Adicionalmente, de forma similar a lo observado en la sección anterior, al remover *sentence_pos*, la interacción entre fatiga y *sentence_pos_squared* se volvió significativa, pero la variable *sentence_pos_squared* por sí sola no.

En el quinto y sexto modelo (Tabla A9 y Tabla A10) se eliminó el posicionamiento de la palabra en la historia (p-valor: 0.082 en el quinto modelo) y su interacción con fatiga (p-valor: 0.054 en el cuarto modelo). Esto no ocurrió en la búsqueda del modelo sin fatiga, lo que indica que la inclusión de la variable fatiga modifica la estructura óptima del modelo, reduciendo la relevancia del índice de palabra como predictor de FFD. Esta diferencia sugiere que el estado de fatiga del participante puede alterar los patrones normales de procesamiento relacionados con la posición de la palabra en el texto.

El modelo final (Tabla A10) aún tiene a *sentence_pos_squared* con un p-valor alto (0.069), pero dado que su interacción con fatiga tiene un efecto significativo (p-valor=0.025), se decidió mantenerla. La interacción entre fatiga y *Regression Rate* resultó marginalmente significativa con un p-valor de 0.041, lo que sugiere que la fatiga modifica sutilmente la relación entre la propensión a realizar regresiones y la duración de la primera fijación. Este hallazgo indica que los participantes fatigados pueden mostrar patrones distintos en cómo las regresiones afectan su procesamiento inicial del texto. Además, el *estimate* positivo de esta interacción indica que a mayor fatiga, mayor es el efecto del *Regression Rate* sobre la duración de la primera fijación. El resto de los atributos resultaron altamente significativos (p-valor < 0.001).

4.2.2 First Pass Reading Time

FPRT muestra un flujo similar en la búsqueda del modelo óptimo. Según el primer modelo (Tabla A11), hay varios atributos que tienen un p-valor alto, siendo la interacción entre fatiga y el posicionamiento en la pantalla la que presenta el p-valor más alto. El orden en el cual se removieron las interacciones es el mismo que en FFD, pero en el caso de FPRT no se removieron los atributos, sino solo las interacciones de *screen_pos*, *sentence_pos* y *word_idx* con fatiga, en ese orden.

Finalmente, la Tabla A14 tiene muchas diferencias con el último modelo de FFD (Tabla A10). La única similitud es la retención de *sentence_pos_squared* a pesar de su p-valor alto, nuevamente justificada por su interacción con fatiga que resultó significativa.

La primera diferencia entre el modelo final de FFD y FPRT es que se invirtieron los niveles de significancia de *word_len* y *word_freq*. En el modelo final de FFD, la longitud de la palabra obtuvo un p-valor de 0.039 y la frecuencia uno menor a 0.001. En FPRT la longitud obtuvo un p-valor menor a 0.001 y la frecuencia un p-valor de 0.047. Adicionalmente, las interacciones entre estas dos variables y fatiga resultaron altamente significativas en FFD, mientras que en FPRT la interacción entre *word_len* y fatiga resultó no significativa, con un p-valor de 0.206. Esto significa que, mientras en las fijaciones iniciales tanto la frecuencia como la longitud de la palabra interactúan de manera importante con la fatiga, en las primeras pasadas de lectura la frecuencia mantiene un rol relevante, pero la longitud parece ejercer un efecto más directo e independiente. En otras palabras, la influencia de la fatiga sobre la dificultad asociada a la longitud de las palabras es más evidente en la

etapa más temprana de la lectura, pero se atenúa en las siguientes fijaciones.

Otra diferencia es que en este modelo no se removieron los atributos *word_idx*, *sentence_pos* y *screen_pos*, lo que indica que los atributos de posicionamiento tienen mucha más relevancia para la predicción de FPRT considerando fatiga. Finalmente, la última diferencia es que la triple interacción entre fatiga, longitud de palabra y su frecuencia resultó no significativa (p-valor = 0.022) mientras que en FFD sí lo fue (p-valor = 0.022).

Por otro lado, *Regression Rate* volvió a mantenerse con un p-valor bajo y un *estimate* positivo, similar al modelo de FFD, aunque esta vez, el p-valor de la interacción entre fatiga y RR se redujo a un valor inferior a 0.01.

4.3 Experimento web

En la estimación de la predictibilidad, no se alcanzó la meta propuesta de 500 participantes por historia. Dado que el promedio de historias completadas por usuario fue bajo, se dividió el conjunto de historias en dos grupos, priorizando un subconjunto que se presentaba primero a los participantes para alcanzar antes la cantidad necesaria de respuestas y poder realizar un análisis al menos con ese grupo. Por falta de tiempo, se decidió enfocar los análisis principalmente en los efectos de fatiga. El experimento se mantendrá activo para acumular más respuestas para un estudio futuro.

5. Conclusiones

Los modelos lineales mixtos (LMM) resultaron fundamentales para analizar los patrones de lectura, tanto con la inclusión de fatiga como sin ella. En los modelos sin fatiga, se encontró que variables léxicas como la longitud y frecuencia de la palabra impactan significativamente en la Duración de la Primera Fijación (FFD), el Tiempo de Lectura de Primera Pasada (FPRT) y las palabras Salteadas (*Skipped*), lo cual es consistente con resultados previos en la literatura (Rayner, 1998). Otras variables que impactaron significativamente sobre estas medidas fueron la posición en la oración y en la pantalla, correspondientes a efectos de integración (*wrap-up*) del entendimiento de la oración y a límites visuales producto de la organización del texto en líneas (Rayner et al., 2000; Kuperman et al., 2010). La posición en pantalla y la tasa de regresión aportaron información única relacionada con la estructura experimental y la complejidad de las palabras.

Al incorporar la fatiga, se observaron cambios en la relevancia de algunos predictores y surgieron interacciones significativas. La fatiga modificó la estructura óptima de los modelos, alterando la importancia de la posición de la palabra en el texto para FFD y mostrando una influencia sutil en la relación entre las regresiones y la duración de la primera fijación. En FPRT, la fatiga impactó de manera diferente sobre la longitud y frecuencia de la palabra, y los atributos de posicionamiento mantuvieron una mayor relevancia. Estos hallazgos sugieren que el estado cognitivo del lector, específicamente la fatiga, modula los procesos de lectura desde las etapas más tempranas del procesamiento del texto.

Por otro lado, el aumento del *Regression Rate* asociado a una mayor fatiga, observado en los resultados de la sección 4.2, se alinea con lo discutido en la sección 1.4 sobre Seoane et al. (2020), donde se postula que una privación de sueño elevada lleva a la reducción de hasta el 40% de capacidad de retención, lo cual en los resultados se refleja en un aumento del RR.

Estos resultados señalan una problemática que ha sido ignorada por mucho tiempo en los estudios cognitivos del lenguaje. La dependencia observada entre las medidas oculares y los puntajes de fatiga indica una posible fuente de variación en los análisis del procesamiento del lenguaje y, como consecuencia, podría llevar a atribuir erróneamente los resultados encontrados a determinados factores de los estudios. La consideración de los ritmos circadianos, con mayor profundidad que en el presente trabajo donde solo se consideraron las horas de vigilia, debería convertirse en un estándar de los estudios cognitivos del lenguaje. Asimismo, la inclusión de estas variables permitiría un análisis más detallado de cómo modulan el rendimiento cognitivo durante la lectura y ayudaría a desarrollar mejores prácticas para el estudio.

Más allá de las contribuciones al estudio de la cognición humana, los hallazgos de esta investigación podrían tener aplicaciones significativas en el desarrollo de modelos de procesamiento del lenguaje natural. Los patrones de atención humana revelados por los movimientos oculares (como las fijaciones, sacadas y regresiones) ofrecen información valiosa sobre qué palabras y estructuras demandan mayor procesamiento cognitivo. Esta información podría incorporarse en arquitecturas de modelos de lenguaje para diseñar mecanismos de atención más biológicamente plausibles. Por ejemplo, los modelos basados en transformers utilizan mecanismos de atención que, aunque efectivos, no necesariamente

reflejan cómo los humanos procesan el lenguaje de manera incremental y selectiva. Incorporar sesgos basados en patrones de *eye-tracking* (como mayor peso en palabras que naturalmente reciben más fijaciones o regresiones) podría mejorar tanto la interpretabilidad como el rendimiento de estos modelos en tareas de comprensión lectora, generación de resúmenes, o predicción de dificultad textual. Explorar estas conexiones representa una dirección prometedora que vincularía la neurociencia cognitiva con la inteligencia artificial, y podría llevar a sistemas de procesamiento del lenguaje más eficientes y centrados en el comportamiento humano.

5.1 Trabajo a futuro

Para futuros trabajos, se considera fundamental completar el experimento online de predictibilidad, buscando alcanzar la meta de más de 500 participantes por historia. Esto permitirá obtener una medida robusta de predictibilidad léxica que, al integrarse en los modelos lineales mixtos, se espera que mejore significativamente su poder explicativo. Adicionalmente, proporcionará un recurso útil para la evaluación de modelos de procesamiento del lenguaje, analizando cuánto se alinean con la cognición humana siguiendo el trabajo de Bianchi et al. (2020).

También es indispensable profundizar el análisis de la fatiga, incorporando nuevos datos que permitan incrementar la cantidad de ensayos. Asimismo, sería deseable aumentar la granularidad y precisión de las medidas de fatiga, incluyendo el sueño en las últimas 48 horas o incluso desarrollando una evaluación fenotípica del ritmo circadiano individual.

Bibliografía

- Balota, D. A. and Rayner, K. (1991). Word recognition processes in foveal and parafoveal vision: The range of influence of lexical variables. In Besner G, D. W., editor, Basic processes in reading: Visual word recognition, pages 198–232. Lawrence Erlbaum Associates, Inc.
- Bianchi, B. (2014). Estudio de predictibilidad en textos naturales: Experimentos comportamentales masivos y de movimientos oculares. Thesis de maestria.
- Bianchi, B., Bengolea, Ferrer, Slezak, F., Shalom, and Kamienkowski (2020). Human and computer estimations of predictability of words in written language. Nature Reaserch.
- Brainard, D. H. (1997). The Psychophysics Toolbox. Spatial Vision, 10(4):433–436.
- Carbajal, M. J. (2013). Organización de procesos cognitivos en lectura natural. Thesis de maestria.
- Casciari, H. (2021). 100 covers de cuentos clásicos. Editorial Orsai SRL.
- Conklin, K., Pellicer-Sánchez, A., and Carrol, G. (2018). Eye-Tracking: A Guide for Applied Linguistics Research. Cambridge University Press.
- Duchon, A., Perea, M., Sebastián-Gallés, N., Martí, A., and Carreiras, M. (2013). EsPal: one-stop shopping for Spanish word properties. Behavior Research Methods, 45(4):1246–1258.
- Ehrlich, S. F. and Rayner, K. (1981). Contextual effects on word perception and eye movements during reading. Journal of Verbal Learning and Verbal Behavior, 20(6):641–655.
- Fernández, G., Shalom, D. E., Kliegl, R., and Sigman, M. (2013). Eye movements during reading proverbs and regular sentences: The incoming word predictability effect. Language, Cognition and Neuroscience.
- Frazier and Rayner (1982). Making and correcting errors during sentence comprehension: Eye movements in the analysis of structurally ambiguous sentences. Cognitive Psychology.
- Gallés (2000). LEXESP: léxico informatizado del español. Publicacions i Edicions de la Universitat de Barcelona.
- Inhoff, A. W. (1984). Two stages of word processing during eye fixations in the reading of prose. Journal of verbal learning and verbal behavior.
- Irwin and Carlson-Radvansky (1996). Cognitive suppression during saccadic eye movements. Cognitive Psychology.
- Irwin, D. E. (1998). Lexical processing during saccadic eye movements. Cognitive Psychology, 36(1):1–27.

- Just, M. A. and Carpenter, P. A. (1980). A theory of reading: From eye fixations to comprehension. Psychological Review, 87:329–354.
- Kliegl, R., Nuthmann, A., and Engbert, R. (2006). Tracking the mind during reading: the influence of past, present, and future words on fixation durations. Journal of Experimental Psychology. General, 135(1):12–35.
- Kuperman, V., Dambacher, M., Nuthmann, A., and Kliegl, R. (2010). The effect of word position on eye-movements in sentence and paragraph reading. Quarterly Journal of Experimental Psychology (2006), 63(9):1838–1857.
- McCulloch, K. (2007). Developing and Implementing a Fatigue Risk Management System. Transport Canada.
- Rayner, K. (1998). Eye movements in reading and information processing: 20 years of research. Psychological Bulletin, 124:372–422. Place: US, Publisher: American Psychological Association.
- Rayner, K., Kambe, G., and Duffy, S. A. (2000). The effect of clause wrap-up on eye movements during reading. The Quarterly Journal of Experimental Psychology. A, Human Experimental Psychology, 53(4):1061–1080.
- Rayner, K., Pollatsek, A., Ashby, J., and Jr, C. C. (2012). Psychology of reading: 2nd edition. New York: Psychology Press.
- Seoane, H. A., Moschetto, L., Orliacq, F., Orliacq, J., Serrano, E., Cazenave, M. I., Vigo, D. E., and Perez-Lloret, S. (2020). Sleep disruption in medicine students and its relationship with impaired academic performance: A systematic review and meta-analysis. Sleep Medicine Reviews, 53:101333.
- Staub and Rayner (2007). Eye movements and on-line comprehension processes. The Oxford Handbook of Psycholinguistics, Oxford Library of Psychology. Oxford University Press.
- Taylor, W. L. (1953). “Cloze Procedure”: A New Tool for Measuring Readability. Journalism Quarterly, 30(4):415–433. Publisher: SAGE Publications.
- Travi, F., Bianchi, B., Slezak, D. F., and Kamienkowski, J. E. (2026). Cuentos: A Large-Scale Eye-Tracking Reading Corpus on Spanish Narrative Texts. Scientific Data.
- Zipf, G. (1949). Human Behavior and the Principle of Least Effort. Cambridge.
- Zoccolotti (2005). Word length effect in early reading and in developmental dyslexia. Springer Science+Business Media B.V.

6. Apéndice

6.1 Modelos sin fatiga

6.1.1 *First Fixation Duration*

$$\text{FFD} \sim \text{word_len} * \text{word_freq} + \text{word_idx} + \text{sentence_pos} + \text{sentence_pos_squared} + \text{screen_pos} + \text{RR} + (1\text{---subj}) + (1\text{---item})$$

	Estimate	SE	P-val	Sig
(Intercept)	1.689	0.003	< 0.001	***
<i>word_len</i>	-0.017	0.006	0.004	**
<i>word_freq</i>	-0.001	0.000	< 0.001	***
<i>word_idx</i>	-0.002	0.000	< 0.001	***
<i>sentence_pos</i>	-0.000	0.002	0.949	
<i>sentence_pos_squared</i>	-0.001	0.002	0.437	
<i>screen_pos</i>	-0.001	0.000	0.001	**
RR	0.030	0.001	< 0.001	***
<i>word_len:word_freq</i>	0.001	0.000	0.001	***

Tab. A1: FFD - Modelo Inicial - AIC: -901204.1432299998

$$\text{FFD} \sim \text{word_len} * \text{word_freq} + \text{word_idx} + \text{sentence_pos_squared} + \text{screen_pos} + \text{RR} + (1\text{---subj}) + (1\text{---item})$$

	Estimate	SE	P-val	Sig
(Intercept)	1.689	0.003	< 0.001	***
<i>word_len</i>	-0.017	0.006	0.004	**
<i>word_freq</i>	-0.001	0.000	< 0.001	***
<i>word_idx</i>	-0.002	0.000	< 0.001	***
<i>sentence_pos_squared</i>	-0.002	0.001	0.007	**
<i>screen_pos</i>	-0.001	0.000	0.001	**
RR	0.030	0.001	< 0.001	***
<i>word_len:word_freq</i>	0.001	0.000	0.001	***

Tab. A2: FFD - Modelo sin *sentence_pos* - AIC: -901217.1643003459

6.1.2 *First Pass Reading Time*

$$\text{FPRT} \sim \text{word_len} * \text{word_freq} + \text{word_idx} + \text{sentence_pos} + \text{sentence_pos_squared} + \text{screen_pos} + \text{RR} + (1\text{---subj}) + (1\text{---item})$$

	Estimate	SE	P-val	Sig
(Intercept)	1.756	0.003	< 0.001	***
<i>word_len</i>	-0.245	0.006	< 0.001	***
<i>word_freq</i>	-0.005	0.000	< 0.001	***
<i>word_idx</i>	-0.003	0.000	< 0.001	***
<i>sentence_pos</i>	-0.008	0.002	< 0.001	***
<i>sentence_pos_squared</i>	0.005	0.002	0.012	*
<i>screen_pos</i>	-0.001	0.000	0.001	**
RR	0.053	0.001	< 0.001	***
<i>word_len:word_freq</i>	0.015	0.000	< 0.001	***

Tab. A3: FPRT - Modelo Inicial - AIC: -844072.6312592546

6.1.3 *Skipped*

$$\text{skipped} \sim \text{word_len} * \text{word_freq} + \text{word_idx} + \text{sentence_pos} + \text{sentence_pos_squared} + \text{screen_pos} + (1\text{---subj}) + (1\text{---item})$$

	Estimate	SE	P-val	Sig
(Intercept)	-5.151	0.055	< 0.001	***
<i>word_len</i>	12.558	0.155	< 0.001	***
<i>word_freq</i>	0.268	0.002	< 0.001	***
<i>word_idx</i>	0.140	0.010	< 0.001	***
<i>sentence_pos</i>	0.460	0.039	< 0.001	***
<i>sentence_pos_squared</i>	-0.369	0.045	< 0.001	***
<i>screen_pos</i>	0.121	0.010	< 0.001	***
<i>word_len:word_freq</i>	-0.595	0.010	< 0.001	***

Tab. A4: *Skipped* - Modelo Inicial - AIC: 733869.3099132364

6.2 Modelos con fatiga

6.2.1 *First Fixation Duration*

$$\text{FFD} \sim \text{fatigue} * (\text{word_len} * \text{word_freq} + \text{word_idx} + \text{sentence_pos} + \text{sentence_pos_squared} + \text{screen_pos}$$

	Estimate	SE	P-val	Sig
(Intercept)	5.305	0.024	< 0.001	***
<i>fatigue</i>	0.007	0.001	< 0.001	***
<i>word_len</i>	-0.033	0.016	0.037	*
<i>word_freq</i>	-0.004	0.001	< 0.001	***
<i>word_idx</i>	-0.007	0.004	0.070	.
<i>sentence_pos</i>	-0.001	0.016	0.937	
<i>sentence_pos_squared</i>	-0.008	0.018	0.667	
<i>screen_pos</i>	-0.022	0.004	< 0.001	***
+ RR) + (1---subj) + (1---item)				
RR	0.139	0.010	< 0.001	***
<i>word_len:word_freq</i>	0.020	0.004	< 0.001	***
<i>fatigue:word_len</i>	0.019	0.005	< 0.001	***
<i>fatigue:word_freq</i>	-0.001	0.000	0.001	***
<i>fatigue:word_idx</i>	0.002	0.001	0.058	.
<i>fatigue:sentence_pos</i>	0.001	0.005	0.761	
<i>fatigue:sentence_pos_squared</i>	0.002	0.005	0.741	
<i>fatigue:screen_pos</i>	-0.000	0.001	0.938	
<i>fatigue:RR</i>	0.007	0.003	0.026	*
<i>fatigue:word_len:word_freq</i>	-0.003	0.001	0.021	*

Tab. A5: FFD - Fatiga - Modelo Inicial - AIC: 98208.17375515537

$$\text{FFD} \sim \text{fatigue} * (\text{word_len} * \text{word_freq} + \text{word_idx} + \text{sentence_pos} + \text{sentence_pos_squared} + \text{RR}) + \text{screen_pos} + (1\text{---subj}) + (1\text{---item})$$

	Estimate	SE	P-val	Sig
(Intercept)	5.305	0.024	< 0.001	***
<i>fatigue</i>	0.007	0.001	< 0.001	***
<i>word_len</i>	-0.033	0.016	0.037	*
<i>word_freq</i>	-0.004	0.001	< 0.001	***
<i>word_idx</i>	-0.007	0.004	0.070	.
<i>sentence_pos</i>	-0.001	0.016	0.937	
<i>sentence_pos_squared</i>	-0.008	0.018	0.667	
RR	0.139	0.010	< 0.001	***
<i>screen_pos</i>	-0.022	0.004	< 0.001	***
<i>word_len:word_freq</i>	0.020	0.004	< 0.001	***
<i>fatigue:word_len</i>	0.019	0.005	< 0.001	***
<i>fatigue:word_freq</i>	-0.001	0.000	0.001	***
<i>fatigue:word_idx</i>	0.002	0.001	0.054	.
<i>fatigue:sentence_pos</i>	0.001	0.005	0.761	
<i>fatigue:sentence_pos_squared</i>	0.002	0.005	0.740	
<i>fatigue:RR</i>	0.007	0.003	0.025	*
<i>fatigue:word_len:word_freq</i>	-0.003	0.001	0.021	*

Tab. A6: FFD - Fatiga - Modelo sin *fatigue:screen_pos* - AIC: 98194.52631658321

$$\text{FFD} \sim \text{fatigue} * (\text{word_len} * \text{word_freq} + \text{word_idx} + \text{sentence_pos_squared} + \text{RR}) + \text{sentence_pos} + \text{screen_pos} + (1\text{---subj}) + (1\text{---item})$$

	Estimate	SE	P-val	Sig
(Intercept)	5.305	0.024	< 0.001	***
<i>fatigue</i>	0.007	0.001	< 0.001	***
<i>word_len</i>	-0.033	0.016	0.037	*
<i>word_freq</i>	-0.004	0.001	< 0.001	***
<i>word_idx</i>	-0.007	0.004	0.070	.
<i>sentence_pos_squared</i>	-0.008	0.018	0.659	
RR	0.139	0.010	< 0.001	***
<i>sentence_pos</i>	-0.001	0.016	0.946	
<i>screen_pos</i>	-0.022	0.004	< 0.001	***
<i>word_len:word_freq</i>	0.020	0.004	< 0.001	***
<i>fatigue:word_len</i>	0.019	0.005	< 0.001	***
<i>fatigue:word_freq</i>	-0.001	0.000	0.001	***
<i>fatigue:word_idx</i>	0.002	0.001	0.054	.
<i>fatigue:sentence_pos_squared</i>	0.003	0.002	0.041	*
<i>fatigue:RR</i>	0.007	0.003	0.026	*
<i>fatigue:word_len:word_freq</i>	-0.003	0.001	0.022	*

Tab. A7: FFD - Fatiga - Modelo sin *fatigue:sentence_pos* - AIC: 98183.67008344959

$$\text{FFD} \sim \text{fatigue} * (\text{word_len} * \text{word_freq} + \text{word_idx} + \text{sentence_pos_squared} + \text{RR}) + \text{screen_pos} + (1 - \text{subj}) + (1 - \text{item})$$

	Estimate	SE	P-val	Sig
(Intercept)	5.305	0.024	< 0.001	***
<i>fatigue</i>	0.007	0.001	< 0.001	***
<i>word_len</i>	-0.033	0.016	0.037	*
<i>word_freq</i>	-0.004	0.001	< 0.001	***
<i>word_idx</i>	-0.007	0.004	0.070	.
<i>sentence_pos_squared</i>	-0.009	0.005	0.100	.
RR	0.139	0.010	< 0.001	***
<i>screen_pos</i>	-0.022	0.004	< 0.001	***
<i>word_len:word_freq</i>	0.020	0.004	< 0.001	***
<i>fatigue:word_len</i>	0.019	0.005	< 0.001	***
<i>fatigue:word_freq</i>	-0.001	0.000	0.054	***
<i>fatigue:word_idx</i>	0.002	0.001	0.054	.
<i>fatigue:sentence_pos_squared</i>	0.003	0.002	0.041	*
<i>fatigue:RR</i>	0.007	0.003	0.026	*
<i>fatigue:word_len:word_freq</i>	-0.003	0.001	0.022	*

Tab. A8: FFD - Fatiga - Modelo sin *sentence_pos* - AIC: 98175.21472785623

$$\text{FFD} \sim \text{fatigue} * (\text{word_len} * \text{word_freq} + \text{word_idx} + \text{sentence_pos_squared} + \text{RR}) + \text{word_idx} + \text{screen_pos} + (1 - \text{subj}) + (1 - \text{item})$$

	Estimate	SE	P-val	Sig
(Intercept)	5.305	0.024	< 0.001	***
<i>fatigue</i>	0.007	0.001	< 0.001	***
<i>word_len</i>	-0.033	0.016	0.037	*
<i>word_freq</i>	-0.004	0.001	< 0.001	***
<i>sentence_pos_squared</i>	-0.009	0.005	0.099	.
RR	0.139	0.010	< 0.001	***
<i>word_idx</i>	-0.007	0.004	0.082	.
<i>screen_pos</i>	-0.022	0.004	< 0.001	***
<i>word_len:word_freq</i>	0.020	0.004	< 0.001	***
<i>fatigue:word_len</i>	0.019	0.005	< 0.001	***
<i>fatigue:word_freq</i>	-0.001	0.000	0.001	***
<i>fatigue:sentence_pos_squared</i>	0.004	0.002	0.025	*
<i>fatigue:RR</i>	0.006	0.003	0.040	*
<i>fatigue:word_len:word_freq</i>	-0.003	0.001	0.023	*

Tab. A9: FFD - Fatiga - Modelo sin *fatigue:word_idx* - AIC: 98165.23958027276

$$\text{FFD} \sim \text{fatigue} * (\text{word_len} * \text{word_freq} + \text{sentence_pos_squared} + \text{RR}) + \text{screen_pos} + (1 - \text{subj}) + (1 - \text{item})$$

	Estimate	SE	P-val	Sig
(Intercept)	5.305	0.024	< 0.001	***
<i>fatigue</i>	0.007	0.001	< 0.001	***
<i>word_len</i>	-0.033	0.016	0.039	*
<i>word_freq</i>	-0.004	0.001	< 0.001	***
<i>sentence_pos_squared</i>	-0.010	0.005	0.069	.
RR	0.141	0.010	< 0.001	***
<i>screen_pos</i>	-0.024	0.004	< 0.001	***
<i>word_len:word_freq</i>	0.020	0.004	< 0.001	***
<i>fatigue:word_len</i>	0.019	0.005	< 0.001	***
<i>fatigue:word_freq</i>	-0.001	0.000	0.001	***
<i>fatigue:sentence_pos_squared</i>	0.003	0.002	0.025	*
<i>fatigue:RR</i>	0.006	0.003	0.041	*
<i>fatigue:word_len:word_freq</i>	-0.003	0.001	0.022	*

Tab. A10: FFD - Fatiga - Modelo sin *word_idx* - AIC: 98157.10875369667

6.2.2 First Pass Reading Time

$$\text{FPRT} \sim \text{fatigue} * (\text{word_len} * \text{word_freq} + \text{word_idx} + \text{sentence_pos} + \text{sentence_pos_squared} + \text{screen_pos} + \text{RR}) + (1 - \text{subj}) + (1 - \text{item})$$

	Estimate	SE	P-val	Sig
(Intercept)	5.300	0.027	< 0.001	***
<i>fatigue</i>	0.004	0.002	0.018	*
<i>word_len</i>	-0.432	0.018	< 0.001	***
<i>word_freq</i>	0.002	0.001	0.048	*
<i>word_idx</i>	-0.015	0.005	0.001	***
<i>sentence_pos</i>	-0.054	0.018	0.002	**
<i>sentence_pos_squared</i>	0.030	0.020	0.138	
<i>screen_pos</i>	-0.018	0.005	< 0.001	***
RR	0.279	0.012	< 0.001	***
<i>word_len:word_freq</i>	0.119	0.004	< 0.001	***
<i>fatigue:word_len</i>	0.007	0.005	0.198	
<i>fatigue:word_freq</i>	-0.001	0.000	0.008	**
<i>fatigue:word_idx</i>	0.002	0.001	0.183	
<i>fatigue:sentence_pos</i>	0.001	0.005	0.835	
<i>fatigue:sentence_pos_squared</i>	0.002	0.006	0.683	
<i>fatigue:screen_pos</i>	0.000	0.001	0.915	
<i>fatigue:RR</i>	0.014	0.003	< 0.001	***
<i>fatigue:word_len:word_freq</i>	0.002	0.001	0.218	

Tab. A11: FPRT - Fatiga - Modelo Inicial - AIC: 122226.6371314067

$$\text{FPRT} \sim \text{fatigue} * (\text{word_len} * \text{word_freq} + \text{word_idx} + \text{sentence_pos} + \text{sentence_pos_squared} + \text{RR}) + \text{screen_pos} + (1\text{---subj}) + (1\text{---item})$$

	Estimate	SE	P-val	Sig
(Intercept)	5.300	0.027	< 0.001	***
<i>fatigue</i>	0.004	0.002	0.017	*
<i>word_len</i>	-0.432	0.018	< 0.001	***
<i>word_freq</i>	0.002	0.001	0.048	*
<i>word_idx</i>	-0.015	0.005	0.001	***
<i>sentence_pos</i>	-0.054	0.018	0.002	**
<i>sentence_pos_squared</i>	0.030	0.020	0.138	
RR	0.279	0.012	< 0.001	***
<i>screen_pos</i>	-0.018	0.005	< 0.001	***
<i>word_len:word_freq</i>	0.119	0.004	< 0.001	***
<i>fatigue:word_len</i>	0.007	0.005	0.197	
<i>fatigue:word_freq</i>	-0.001	0.000	0.008	**
<i>fatigue:word_idx</i>	0.002	0.001	0.165	
<i>fatigue:sentence_pos</i>	0.001	0.005	0.835	
<i>fatigue:sentence_pos_squared</i>	0.002	0.006	0.684	
<i>fatigue:RR</i>	0.014	0.003	< 0.001	***
<i>fatigue:word_len:word_freq</i>	0.002	0.001	0.218	

Tab. A12: FPRT - Fatiga - Modelo sin *fatigue:screen_pos* - AIC: 122213.21477388826

$$\text{FPRT} \sim \text{fatigue} * (\text{word_len} * \text{word_freq} + \text{word_idx} + \text{sentence_pos_squared} + \text{RR}) + \text{sentence_pos} + \text{screen_pos} + (1\text{---subj}) + (1\text{---item})$$

	Estimate	SE	P-val	Sig
(Intercept)	5.300	0.027	< 0.001	***
<i>fatigue</i>	0.004	0.002	0.017	*
<i>word_len</i>	-0.432	0.018	< 0.001	***
<i>word_freq</i>	0.002	0.001	0.048	*
<i>word_idx</i>	-0.015	0.005	0.001	***
<i>sentence_pos_squared</i>	0.029	0.020	0.140	
RR	0.279	0.012	< 0.001	***
<i>sentence_pos</i>	-0.053	0.018	0.002	**
<i>screen_pos</i>	-0.018	0.005	< 0.001	***
<i>word_len:word_freq</i>	0.119	0.004	< 0.001	***
<i>fatigue:word_len</i>	0.007	0.005	0.200	
<i>fatigue:word_freq</i>	-0.001	0.000	0.008	**
<i>fatigue:word_idx</i>	0.002	0.001	0.165	
<i>fatigue:sentence_pos_squared</i>	0.003	0.002	0.046	*
<i>fatigue:RR</i>	0.014	0.003	< 0.001	***
<i>fatigue:word_len:word_freq</i>	0.002	0.001	0.214	

Tab. A13: FPRT - Fatiga - Modelo sin *fatigue:sentence_pos* - AIC: 122202.52892676006

$$\text{FPRT} \sim \text{fatigue} * (\text{word_len} * \text{word_freq} + \text{sentence_pos_squared} + \text{RR}) + \text{word_idx} + \text{sentence_pos} + \text{screen_pos} + (1\text{---subj}) + (1\text{---item})$$

	Estimate	SE	P-val	Sig
(Intercept)	5.300	0.027	< 0.001	***
<i>fatigue</i>	0.004	0.002	0.015	*
<i>word_len</i>	-0.432	0.018	< 0.001	***
<i>word_freq</i>	0.002	0.001	0.047	*
<i>sentence_pos_squared</i>	0.029	0.020	0.140	
RR	0.279	0.012	< 0.001	***
<i>word_idx</i>	-0.015	0.005	0.001	**
<i>sentence_pos</i>	-0.053	0.018	0.002	**
<i>screen_pos</i>	-0.018	0.005	< 0.001	***
<i>word_len:word_freq</i>	0.119	0.004	< 0.001	***
<i>fatigue:word_len</i>	0.007	0.005	0.206	
<i>fatigue:word_freq</i>	-0.001	0.000	0.007	**
<i>fatigue:sentence_pos_squared</i>	0.004	0.002	0.032	*
<i>fatigue:RR</i>	0.014	0.003	< 0.001	***
<i>fatigue:word_len:word_freq</i>	0.002	0.001	0.210	

Tab. A14: FPRT - Fatiga - Modelo sin *fatigue:word_idx* - AIC: 122191.00174807486